Learning Model Predictive Control per compiti iterativi

Guida alla lettura di U. Rosolia e F. Borrelli,
Learning Model Predictive Control for Iterative Tasks:
A Computationally Efficient Approach for Linear System,
IFAC PapersOnLine 50-1 (2017), pp. 3142–3147

Indice

1 Di che cosa parla il paper **3**

2 Richiami teorici **4**
2.1 Sistemi lineari vincolati 4
2.2 Insiemi convessi, inviluppo convesso, funzioni convesse 5
2.3 Il lemma che regge tutto il paper 6
2.4 Problemi di ottimo convessi: LP, QP, MIP 6
2.5 Controllo ottimo a orizzonte infinito 7
2.6 Invarianza e stabilità secondo Lyapunov 7
2.7 Il controllo predittivo e le sue garanzie classiche 8
2.8 Compiti iterativi e Iterative Learning Control 9

3 Il problema affrontato dal paper **10**

4 L'insieme terminale imparato: il safe set **11**
4.1 Il safe set campionato 11
4.2 Il safe set convesso 11

5 Il costo terminale imparato: la funzione baricentrica **12**
5.1 Costi realizzati 12
5.2 La funzione baricentrica 13
5.3 Proprietà della funzione baricentrica 14
5.4 Iterazioni di durata finita 15

6 Il controllore LMPC **15**
6.1 Il problema risolto a ogni istante 15
6.2 Perché è un problema convesso 16
6.3 L'iterazione zero 17
6.4 Lo schema complessivo 17

7 Fattibilità ricorsiva e stabilità **18**

8 Miglioramento e ottimalità **20**
8.1 Il costo non peggiora da un'iterazione all'altra 20
8.2 La traiettoria limite è ottima 20

9 L'esempio del paper: LQR vincolato **21**

10 Collegamenti con il libro di Borrelli, Bemporad e Morari **22**
10.1 Il Teorema 1 del paper è il Teorema 12.2 del libro 22
10.2 Insiemi controllabili, invarianti e regione di attrazione 24
10.3 La funzione baricentrica e il capitolo 13 25
10.4 Programmazione multiparametrica: la forma di P^j e di $J_{0\to N}^{\mathrm{LMPC},j}$ 26
10.5 Orizzonte infinito, CLQR e ottimalità 27
10.6 Il doppio integratore nel libro 27
10.7 Dal MIP al QP: un rilassamento che non perde nulla 28
10.8 Che cosa aggiunge il paper rispetto al libro 28

11 Ipotesi, limiti e osservazioni **28**

12 Riepilogo **29**

1 Di che cosa parla il paper

Molti sistemi di controllo eseguono *lo stesso compito più volte*: un robot ripete lo stesso movimento di presa, un'auto da corsa percorre lo stesso circuito giro dopo giro, un reattore chimico ripete lo stesso lotto di produzione. Ogni esecuzione del compito si chiama *iterazione* (o *prova*). Se le iterazioni partono tutte dallo stesso stato iniziale e hanno lo stesso obiettivo, è naturale chiedersi se il controllore possa *imparare* dalle esecuzioni passate e fare meglio a ogni nuova esecuzione.

Il paper propone un controllore di questo tipo, chiamato *Learning Model Predictive Control* (LMPC). È un MPC del tutto ordinario nella struttura (a ogni istante risolve un problema di ottimo su un orizzonte finito e applica il primo ingresso), con una differenza: **l'insieme terminale e il costo terminale non sono progettati a priori, ma costruiti con i dati delle iterazioni precedenti**. Più precisamente:

- l'insieme terminale è l'*inviluppo convesso* di tutti gli stati visitati nelle iterazioni passate (il *convex safe set*);
- il costo terminale è un'interpolazione convessa dei costi *effettivamente pagati* a partire da quegli stati (la *funzione baricentrica*).

Con queste due scelte il paper dimostra quattro proprietà:

(i) *stabilità asintotica*: a ogni iterazione il sistema in anello chiuso converge all'equilibrio desiderato x_F;

(ii) *fattibilità ricorsiva*: se il problema di ottimo è risolvibile all'istante iniziale, lo resta per sempre, e i vincoli su stato e ingresso non vengono mai violati;

(iii) *miglioramento delle prestazioni*: il costo pagato in un'iterazione non è mai maggiore di quello dell'iterazione precedente;

(iv) *ottimalità globale*: se le traiettorie convergono a una traiettoria limite al crescere del numero di iterazioni, quella traiettoria è la soluzione ottima del problema a orizzonte *infinito*.

Le proprietà (i) e (ii) sono i requisiti standard di ogni MPC ben progettato; (iii) e (iv) sono quelle tipiche dell'apprendimento.

Il LMPC era già stato proposto dagli stessi autori per sistemi non lineari (Rosolia e Borrelli, 2016). In quella versione l'insieme terminale è un insieme *discreto* di punti, e imporre che lo stato finale predetto cada su uno di quei punti richiede variabili intere: il problema da risolvere a ogni istante è un *mixed-integer program*, molto costoso. Il contributo di questo paper è mostrare che, **quando il sistema è lineare**, si può sostituire l'insieme di punti con il suo inviluppo convesso senza perdere nessuna garanzia: il problema diventa convesso (un QP, se il costo è quadratico) e si risolve in tempi di diversi ordini di grandezza inferiori.

Idea chiave. Un MPC è stabile e ricorsivamente fattibile se ha un insieme terminale *controllo-invariante* e un costo terminale che si comporta da *funzione di Lyapunov* su quell'insieme. Il LMPC non progetta questi due oggetti: li ricava dai dati. Il motivo per cui funziona è una proprietà dei sistemi lineari con vincoli e costi convessi: *ogni combinazione convessa di traiettorie realizzate è ancora una traiettoria ammissibile, e il suo costo non supera la combinazione convessa dei costi.* Tutto il paper discende da questa osservazione.

Come è organizzato questo documento. La sezione 2 richiama le basi teoriche che servono: insiemi e funzioni convesse, problemi di ottimo convessi, controllo ottimo a orizzonte infinito, invarianza e stabilità secondo Lyapunov, le condizioni classiche di stabilità dell'MPC, il controllo iterativo. Le sezioni dalla 3 alla 8 seguono il paper nell'ordine in cui è scritto, spiegando ogni definizione e ricostruendo le dimostrazioni passo per passo. La sezione 9 commenta l'esempio numerico del paper in modo qualitativo. La sezione 10 mette il paper in relazione con il libro di Borrelli, Bemporad e Morari, *Predictive Control for Linear and Hybrid Systems* (Cambridge University Press, 2017), di cui Borrelli, secondo autore del paper, è il primo autore: mostra da quali risultati del libro discendono i ragionamenti del paper e che cosa il paper aggiunge. La sezione 11 discute ipotesi e limiti, la sezione 12 riassume.

Convenzioni. Le equazioni del paper sono citate come [P-n]: [P-18] è l'equazione (18) del paper. I rimandi al libro sono scritti come [BBM, Teorema 12.2], con la numerazione del libro. Le equazioni di questo documento hanno la numerazione normale. Il paper usa la lettera k con due significati diversi (indice di iterazione nelle sommatorie e istante di predizione nel problema di MPC) e la lettera t sia per l'istante corrente sia come indice muto nelle sommatorie sui dati. Qui i significati sono separati come nella tabella 1.

Tabella 1: Notazione usata nel documento.

Simbolo	Significato
$x \in \mathbb{R}^n$, $u \in \mathbb{R}^m$	stato e ingresso del sistema
$\mathcal{X}, \mathcal{U}$	insiemi (convessi) dei valori ammessi per stato e ingresso
x_S, x_F	stato iniziale di ogni iterazione, equilibrio finale
$h(x,u)$	costo di stadio
j	iterazione corrente
i	iterazione generica (passata), $i \le j$
t	istante corrente all'interno di un'iterazione
s	istante a cui è stato registrato un dato, x_s^i, u_s^i
k	istante predetto: $x_{k\|t}$ è la predizione di x_k fatta all'istante t
l	indice muto nelle somme dei costi
N	orizzonte di predizione
x_s^i, u_s^i	stato e ingresso *realizzati* all'istante s dell'iterazione i
$J^i_{s\to\infty}(x_s^i)$	costo realizzato da x_s^i in poi (*cost-to-go*)
$J^*_{0\to\infty}(x)$	costo ottimo a orizzonte infinito a partire da x
$\mathcal{SS}^j$, $\mathcal{CS}^j$	safe set campionato e safe set convesso dopo l'iterazione j
λ_s^i	peso del dato x_s^i in una combinazione convessa
$P^j(x)$	funzione baricentrica (costo terminale)
$J^{\mathrm{LMPC},j}_{t\to t+N}(x_t^j)$	costo ottimo del problema LMPC all'istante t dell'iterazione j

2 Richiami teorici

2.1 Sistemi lineari vincolati

Il paper considera sistemi lineari a tempo discreto e tempo invarianti

$$x_{t+1} = Ax_t + Bu_t, \qquad x_t \in \mathbb{R}^n,\ u_t \in \mathbb{R}^m, \tag{1}$$

soggetti ai vincoli

$$x_t \in \mathcal{X}, \qquad u_t \in \mathcal{U} \qquad \forall t \in \mathbb{Z}_{\ge 0}, \tag{2}$$

con $\mathcal{X}$ e $\mathcal{U}$ insiemi *convessi*. Nella pratica sono quasi sempre poliedri, cioè insiemi descritti da disuguaglianze lineari, ad esempio limiti superiori e inferiori su ogni componente ($\underline{x} \le x \le \overline{x}$, $\underline{u} \le u \le \overline{u}$).

Un punto x_F è un *equilibrio del sistema non forzato* se

$$x_F = Ax_F, \tag{3}$$

cioè se, applicando $u = 0$, lo stato resta in x_F. Il caso più comune è $x_F = 0$. Il paper chiede che x_F sia anche *ammissibile*, cioè $x_F \in \mathcal{X}$ e $0 \in \mathcal{U}$: il sistema può restare in x_F per sempre senza violare i vincoli.

2.2 Insiemi convessi, inviluppo convesso, funzioni convesse

Definizione 2.1 (Combinazione convessa)**.** Dati i punti $z_1, \dots, z_M \in \mathbb{R}^n$, una loro *combinazione convessa* è un punto

$$z = \sum_{r=1}^{M} \lambda_r z_r, \qquad \lambda_r \ge 0, \qquad \sum_{r=1}^{M} \lambda_r = 1.$$

I pesi λ_r sono anche detti *coordinate baricentriche* di z rispetto ai punti z_r.

Geometricamente, la combinazione convessa di due punti è un punto del segmento che li unisce; quella di tre punti è un punto del triangolo che ha i tre punti per vertici; e così via.

Definizione 2.2 (Insieme convesso, inviluppo convesso)**.** Un insieme $C \subseteq \mathbb{R}^n$ è *convesso* se contiene il segmento che unisce due qualsiasi dei suoi punti. L'*inviluppo convesso* $\mathrm{Conv}(S)$ di un insieme S è il più piccolo insieme convesso che contiene S; coincide con l'insieme di tutte le combinazioni convesse (finite) di punti di S. Se S è un insieme finito di punti, $\mathrm{Conv}(S)$ è un *politopo*: un poliedro limitato i cui vertici sono alcuni dei punti di S.

Un politopo si può descrivere in due modi equivalenti: con i suoi vertici (*rappresentazione V*: "tutte le combinazioni convesse di questi punti") o con le disuguaglianze delle sue facce (*rappresentazione H*: $\{x : Hx \le g\}$). Passare da una all'altra è costoso in dimensione alta: il libro [BBM, Sez. 4.4.2] osserva che il calcolo dell'inviluppo convesso in forma H ha un costo esponenziale nel numero di facce. Il paper userà sempre la rappresentazione V, che il libro scrive in forma compatta [BBM, eq. (4.8)] come

$$\mathrm{Conv}(V) = \{V\lambda : \lambda \ge 0,\ \mathbf{1}^\top \lambda = 1\},$$

con V matrice che ha per colonne i punti: non calcola mai le facce dell'inviluppo convesso, ma tratta i pesi λ come variabili di ottimizzazione.

Definizione 2.3 (Funzione convessa)**.** Una funzione $f : C \to \mathbb{R}$, con C convesso, è *convessa* se

$$f(\theta z_1 + (1-\theta) z_2) \le \theta f(z_1) + (1-\theta) f(z_2) \qquad \forall z_1, z_2 \in C,\ \theta \in [0,1].$$

Il costo di stadio $h(x,u)$ è *congiuntamente convesso* se è convesso come funzione della coppia (x,u), cioè del vettore $(x,u) \in \mathbb{R}^{n+m}$.

L'esempio tipico è il costo quadratico $h(x,u) = x^\top Q x + u^\top R u$ con $Q \succeq 0$ e $R \succeq 0$, congiuntamente convesso perché è una forma quadratica semidefinita positiva del vettore (x,u).

Lemma 2.4 (Disuguaglianza di Jensen)**.** *Se f è convessa, per ogni combinazione convessa vale*

$$f\Big(\sum_{r=1}^{M} \lambda_r z_r\Big) \le \sum_{r=1}^{M} \lambda_r f(z_r).$$

Dimostrazione. Per $M = 2$ è la definizione di convessità. Se vale per $M-1$ punti e $\lambda_M < 1$, si scrive $\sum_{r=1}^{M} \lambda_r z_r = (1-\lambda_M)\, w + \lambda_M z_M$ con $w = \sum_{r<M} \frac{\lambda_r}{1-\lambda_M} z_r$, che è una combinazione convessa di $M-1$ punti. Applicando la definizione e poi l'ipotesi induttiva a w si ottiene la tesi. (Se $\lambda_M = 1$ la tesi è banale.) □

In parole: *la funzione valutata nella media pesata non supera la media pesata dei valori.* Nel paper la disuguaglianza di Jensen è il passaggio centrale della dimostrazione di stabilità (equazione [P-31]).

2.3 Il lemma che regge tutto il paper

Il risultato seguente non compare nel paper come enunciato separato, ma è usato in tutte le dimostrazioni. Conviene isolarlo subito.

Lemma 2.5 (Combinazioni convesse di traiettorie)**.** *Siano $(x_s^{(r)}, u_s^{(r)})_{s\geq 0}$, per $r = 1, \dots, M$, traiettorie del sistema* (1)*: $x_{s+1}^{(r)} = Ax_s^{(r)} + Bu_s^{(r)}$, con $x_s^{(r)} \in \mathcal{X}$ e $u_s^{(r)} \in \mathcal{U}$ per ogni s. Siano $\lambda_r \geq 0$ con $\sum_r \lambda_r = 1$. Allora le successioni*

$$\tilde{x}_s = \sum_{r=1}^{M} \lambda_r x_s^{(r)}, \qquad \tilde{u}_s = \sum_{r=1}^{M} \lambda_r u_s^{(r)}$$

1. *sono ancora una traiettoria del sistema: $\tilde{x}_{s+1} = A\tilde{x}_s + B\tilde{u}_s$;*
2. *rispettano i vincoli: $\tilde{x}_s \in \mathcal{X}$, $\tilde{u}_s \in \mathcal{U}$;*
3. *hanno un costo non maggiore della combinazione dei costi, se h è congiuntamente convesso: $h(\tilde{x}_s, \tilde{u}_s) \leq \sum_r \lambda_r h(x_s^{(r)}, u_s^{(r)})$.*

Dimostrazione. (1) Per linearità, $A\tilde{x}_s + B\tilde{u}_s = \sum_r \lambda_r (Ax_s^{(r)} + Bu_s^{(r)}) = \sum_r \lambda_r x_{s+1}^{(r)} = \tilde{x}_{s+1}$. (2) $\tilde{x}_s$ è combinazione convessa di punti di $\mathcal{X}$, che è convesso; lo stesso per $\tilde{u}_s$ e $\mathcal{U}$. (3) È la disuguaglianza di Jensen applicata a h nei punti $(x_s^{(r)}, u_s^{(r)})$. □

Osservazione 2.6. Il punto (1) è il *principio di sovrapposizione* dei sistemi lineari, ristretto a pesi che sommano a uno. Per un sistema non lineari $x_{s+1} = f(x_s, u_s)$ è falso: la media di due traiettorie in generale non è una traiettoria. È esattamente questo il motivo per cui il LMPC non lineare del 2016 non può usare l'inviluppo convesso e deve ricorrere a variabili intere.

2.4 Problemi di ottimo convessi: LP, QP, MIP

Un problema di ottimo $\min_z f(z)$ con $z \in Z$ è *convesso* se f è convessa e Z è convesso. La proprietà fondamentale è che *ogni minimo locale è anche globale*: non esistono "valli" secondarie in cui un algoritmo possa rimanere intrappolato. Due casi particolari interessano qui:

- *programmazione lineare* (LP): costo lineare $c^\top z$, vincoli lineari $Gz \leq g$, $Ez = e$;
- *programmazione quadratica* (QP): costo $\frac{1}{2} z^\top H z + f^\top z$ con $H \succeq 0$, vincoli lineari.

Entrambi si risolvono in tempo polinomiale con algoritmi maturi (simplesso, punti interni, insiemi attivi: `quadprog` in MATLAB è uno di questi). Il libro li tratta in [BBM, Cap. 2] e i metodi numerici in [BBM, Cap. 3].

Se invece alcune variabili devono essere *intere* (tipicamente binarie, $\delta \in \{0, 1\}$), il problema è un *mixed-integer program* (MIP, oppure MIQP se il costo è quadratico). L'insieme ammissibile non è più convesso: è un'unione di pezzi, uno per ogni combinazione delle variabili binarie. Gli algoritmi esatti (*branch and bound*) esplorano in modo intelligente queste combinazioni, ma nel caso peggiore il loro numero cresce in modo esponenziale con il numero di variabili binarie: i

problemi con variabili 0-1 sono in generale NP-completi [BBM, Sez. 2.4 e 17.4.1]. Nel LMPC del 2016 c'è una variabile binaria per ogni stato memorizzato, e gli stati memorizzati aumentano a ogni iterazione: da qui il costo computazionale che questo paper elimina.

2.5 Controllo ottimo a orizzonte infinito

Il problema che il paper vuole risolvere è

$$\begin{aligned} J^*_{0\to\infty}(x_S) = \min_{u_0,u_1,\dots} \ & \sum_{k=0}^{\infty} h(x_k,u_k) \\ \text{s.t.} \ \ & x_{k+1} = Ax_k + Bu_k, \quad x_0 = x_S, \\ & x_k \in \mathcal{X},\ u_k \in \mathcal{U} \quad \forall k \geq 0. \end{aligned} \tag{4}$$

La funzione $x \mapsto J^*_{0\to\infty}(x)$, che associa a ogni stato iniziale il costo ottimo, si chiama *funzione valore* (o *costo ottimo da percorrere*, *optimal cost-to-go*). Essa soddisfa il *principio di ottimalità di Bellman*:

$$J^*_{0\to\infty}(x) = \min_{u\in\mathcal{U},\ Ax+Bu\in\mathcal{D}} \Big\{ h(x,u) + J^*_{0\to\infty}(Ax+Bu) \Big\}, \tag{5}$$

dove $\mathcal{D}$ è l'insieme degli stati da cui il problema è risolvibile. In parole: il costo ottimo da x è il costo del primo passo più il costo ottimo dallo stato in cui si arriva. Se si conoscesse $J^*_{0\to\infty}$, basterebbe risolvere a ogni istante il problema a un passo (5) per ottenere il controllo ottimo a orizzonte infinito [BBM, Sez. 7.4, eq. (7.21)–(7.22)].

Senza vincoli e con costo quadratico, $J^*_{0\to\infty}(x) = x^\top P_\infty x$ con P_∞ soluzione dell'equazione algebrica di Riccati (LQR). *Con* i vincoli (*constrained* LQR, CLQR) non esiste una formula chiusa: la funzione valore è quadratica a tratti su una partizione poliedrica dello spazio di stato, e calcolarla esattamente è possibile solo per problemi piccoli [BBM, Sez. 11.3.4–11.3.5]. L'esempio del paper (sezione 9) usa proprio questa soluzione esatta come termine di paragone.

2.6 Invarianza e stabilità secondo Lyapunov

Definizione 2.7 (Insieme controllo-invariante, [BBM, Def. 10.9])**.** Un insieme $C \subseteq \mathcal{X}$ è *controllo-invariante* per il sistema (1) con i vincoli (2) se

$$\forall x \in C \quad \exists u \in \mathcal{U} : \quad Ax + Bu \in C.$$

Se lo stato è in un insieme controllo-invariante, esiste sempre un ingresso ammissibile che lo mantiene nell'insieme, e quindi lo si può mantenere nell'insieme (e nei vincoli) *per sempre*. Per questo gli insiemi controllo-invarianti sono detti anche "sicuri".

Si consideri ora un sistema in anello chiuso $x_{t+1} = f(x_t)$ con un equilibrio $x_F = f(x_F)$.

Definizione 2.8 (Stabilità asintotica)**.** L'equilibrio x_F è *stabile* se per ogni $\varepsilon > 0$ esiste $\delta > 0$ tale che $\|x_0 - x_F\| < \delta$ implica $\|x_t - x_F\| < \varepsilon$ per ogni t; è *asintoticamente stabile* se è stabile e inoltre $x_t \to x_F$ per $t \to \infty$ (per stati iniziali in un opportuno insieme, la *regione di attrazione*).

Teorema 2.9 (Lyapunov, tempo discreto, [BBM, Teorema 7.2])**.** *Sia Ω un insieme positivamente invariante per $x_{t+1} = f(x_t)$ con $x_F \in \Omega$. Se esiste una funzione $V : \Omega \to \mathbb{R}$ continua in x_F con*

$$V(x_F) = 0, \qquad V(x) > 0 \ \ \forall x \neq x_F, \qquad V(f(x)) - V(x) \leq -\alpha(x) < 0 \ \ \forall x \neq x_F,$$

con α continua e definita positiva, allora x_F è asintoticamente stabile con regione di attrazione Ω.

L'idea è intuitiva: V è una sorta di "energia" che è nulla solo all'equilibrio e diminuisce strettamente a ogni passo; non potendo diminuire per sempre di quantità non trascurabili, deve tendere a zero, e con essa la distanza da x_F. Nell'MPC il ruolo di V è svolto dal costo ottimo del problema di predizione, e $\alpha(x)$ è il costo di stadio h.

2.7 Il controllo predittivo e le sue garanzie classiche

L'MPC rende trattabile il problema (4) troncandolo a un orizzonte finito N. All'istante t, misurato lo stato x_t, risolve

$$
\begin{aligned}
J_N^{\mathrm{MPC}}(x_t) = \min_{u_{t|t},\dots,u_{t+N-1|t}} \quad & \sum_{k=t}^{t+N-1} h(x_{k|t}, u_{k|t}) + V_f(x_{t+N|t}) \\
\text{s.t.} \quad & x_{k+1|t} = Ax_{k|t} + Bu_{k|t}, \quad x_{t|t} = x_t, \\
& x_{k|t} \in \mathcal{X},\ u_{k|t} \in \mathcal{U}, \quad k = t, \dots, t+N-1, \\
& x_{t+N|t} \in \mathcal{X}_f,
\end{aligned}
\tag{6}
$$

applica il primo ingresso $u_t = u^*_{t|t}$ e all'istante successivo ripete tutto con il nuovo stato misurato (*orizzonte recedente*, figura 1). Gli oggetti $\mathcal{X}_f$ (*insieme terminale*) e V_f (*costo terminale*) rappresentano "ciò che succede dopo l'orizzonte".

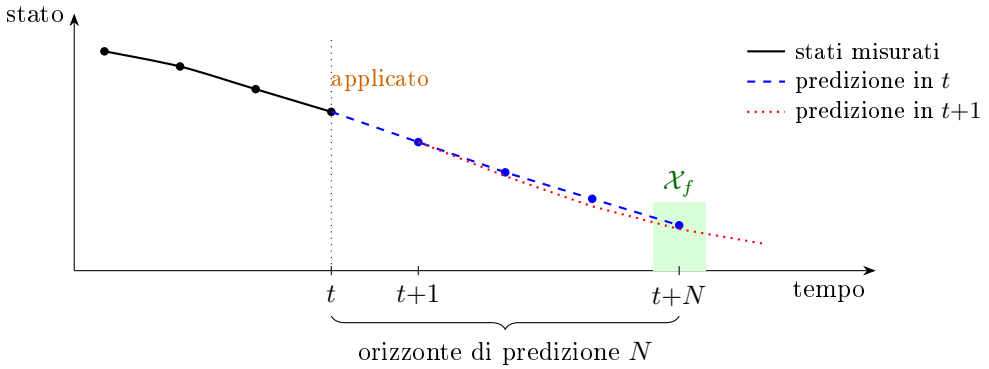


Figura 1: Orizzonte recedente. All'istante t si predice l'evoluzione per N passi, imponendo che lo stato finale cada nell'insieme terminale $\mathcal{X}_f$; si applica solo il primo ingresso. All'istante $t+1$ la finestra si sposta di un passo e il problema viene risolto di nuovo.

Troncare l'orizzonte ha un prezzo. Un MPC "ingenuo" (senza $\mathcal{X}_f$ e V_f adeguati) è *miope*: può portare il sistema in uno stato da cui, qualche passo dopo, non esiste più alcun ingresso che rispetti i vincoli (perdita di fattibilità), oppure può non convergere all'equilibrio (perdita di stabilità). La teoria classica (Mayne et al., 2000) dà condizioni sufficienti per evitare entrambi i problemi.

Ipotesi 2.10 (Condizioni classiche sugli ingredienti terminali)**.**

1. $h(x_F, 0) = 0$ e $h(x, u) > 0$ per ogni $(x, u) \neq (x_F, 0)$;
2. $\mathcal{X}_f \subseteq \mathcal{X}$ è controllo-invariante e contiene x_F;
3. su $\mathcal{X}_f$ il costo terminale V_f è una *funzione di Lyapunov di controllo* [BBM, Remark 12.3]: per ogni $x \in \mathcal{X}_f$ esiste $u \in \mathcal{U}$ tale che

$$
Ax + Bu \in \mathcal{X}_f \qquad \text{e} \qquad V_f(Ax + Bu) - V_f(x) \leq -h(x, u). \tag{7}
$$

Teorema 2.11 (Stabilità dell'MPC, [BBM, Teorema 12.2])**.** *Sotto l'ipotesi 2.10, se il problema* (6) *ha soluzione in* $t = 0$*, allora ha soluzione per ogni* $t \geq 0$ *e lungo l'anello chiuso*

$$
J_N^{\mathrm{MPC}}(x_{t+1}) - J_N^{\mathrm{MPC}}(x_t) \leq -h(x_t, u_t). \tag{8}
$$

Di conseguenza (con le opportune ipotesi di continuità) x_F *è asintoticamente stabile, con regione di attrazione l'insieme degli stati da cui* (6) *ha soluzione.*

Idea della dimostrazione. Sia $(u^*_{t|t}, \dots, u^*_{t+N-1|t})$ la soluzione ottima all'istante t e $x^*_{t+N|t} \in \mathcal{X}_f$ lo stato finale predetto. Per il punto 3 dell'ipotesi esiste $\bar{u}$ che mantiene $x^*_{t+N|t}$ in $\mathcal{X}_f$. All'istante $t+1$ si considera la sequenza *traslata*

$$(u^*_{t+1|t}, \dots, u^*_{t+N-1|t},\ \bar{u}) :$$

le prime $N-1$ mosse sono quelle già pianificate, l'ultima è quella fornita dall'ipotesi. Poiché il modello è esatto, $x_{t+1} = x^*_{t+1|t}$ e la sequenza traslata produce gli stessi stati predetti, più un ultimo stato $\bar{x} = Ax^*_{t+N|t} + B\bar{u} \in \mathcal{X}_f$: è *ammissibile* (questo dà la fattibilità ricorsiva). Il suo costo è quello ottimo all'istante t, meno il primo termine $h(x_t, u_t)$, meno il vecchio costo terminale, più il nuovo termine di stadio e il nuovo costo terminale:

$$J^{\mathrm{MPC}}_N(x_t) - h(x_t, u_t) + \underbrace{h(x^*_{t+N|t}, \bar{u}) + V_f(\bar{x}) - V_f(x^*_{t+N|t})}_{\leq 0 \text{ per la (7)}}.$$

Il costo ottimo in $t+1$ non supera quello di una soluzione ammissibile, e si ottiene la (8). Il costo ottimo è quindi una funzione di Lyapunov e il teorema 2.9 conclude. □

Idea chiave. Il teorema 2.11 ha bisogno di una sola cosa "difficile": una coppia $(\mathcal{X}_f, V_f)$ che soddisfi la (7). Nella pratica la si costruisce attorno all'equilibrio con un controllore lineare locale (ad esempio LQR) e un insieme invariante piccolo, il che rende la regione di attrazione piccola e obbliga a orizzonti lunghi. Il LMPC usa la stessa dimostrazione, ma con una coppia $(\mathcal{X}_f, V_f)$ ricavata dai dati, grande e sempre più vicina alla coppia ideale (dominio di $J^*_{0\to\infty}$, $J^*_{0\to\infty}$).

2.8 Compiti iterativi e Iterative Learning Control

L'*Iterative Learning Control* (ILC) studia sistemi che ripetono lo stesso compito. Il tempo ha due scale: l'istante t *all'interno* di un'iterazione e l'indice j *dell'iterazione*. Le iterazioni partono dallo stesso stato iniziale, e alla fine di ognuna i dati registrati sono disponibili per progettare la successiva (figura 2).

Nella forma classica l'ILC insegue un riferimento r_t noto e aggiorna l'ingresso con l'errore dell'iterazione precedente, con leggi del tipo

$$u^{j+1}_t = u^j_t + L\,(r_{t+1} - y^j_{t+1}),$$

in modo che l'errore di inseguimento si annulli al crescere di j. Questo presuppone che *il riferimento sia noto*. In molti compiti però il riferimento "migliore" è proprio ciò che non si sa: in una gara automobilistica non si conosce a priori la traiettoria che minimizza il tempo sul giro. Il LMPC è un controllo iterativo *senza riferimento* (*reference-free*): l'obiettivo non è inseguire una traiettoria, ma minimizzare un costo; ciò che si impara dalle iterazioni non è un segnale di correzione, ma una descrizione sempre migliore di *dove* il sistema può stare in sicurezza e di *quanto costa* arrivare alla fine da lì.

Il paper cita anche un lavoro (Tamar et al., 2016) in cui il costo terminale di un MPC è appreso da una rete neurale: funziona in pratica, ma senza alcuna garanzia di stabilità, fattibilità o miglioramento. Il LMPC ottiene invece queste garanzie perché il costo terminale non è un'approssimazione generica, ma è costruito con costi *realmente pagati* lungo traiettorie *realmente percorse*.

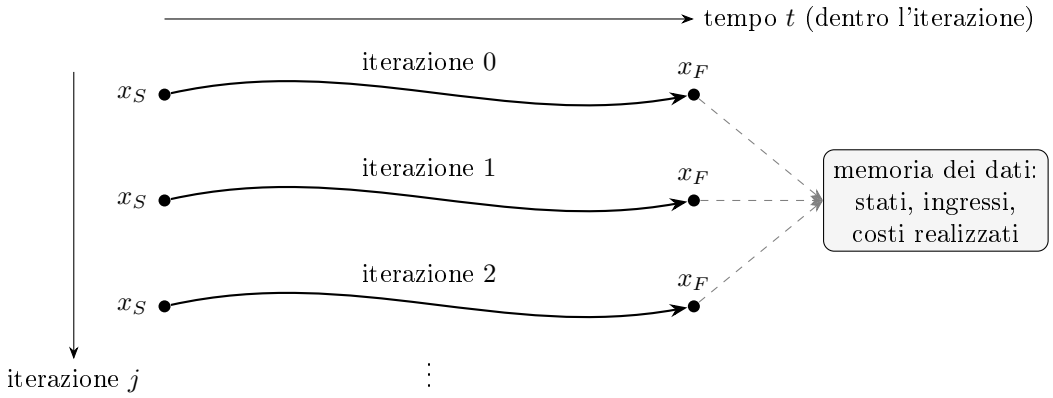


Figura 2: Le due scale temporali di un compito iterativo. Ogni iterazione parte da x_S e deve arrivare a x_F; a fine iterazione la traiettoria percorsa e i costi pagati vengono memorizzati e usati per progettare le iterazioni successive.

3 Il problema affrontato dal paper

Dati di un'iterazione. All'iterazione j il sistema (1) viene fatto evolvere e si registrano le successioni di ingressi e stati ([P-3])

$$\mathbf{u}^j = [u_0^j,\, u_1^j,\, \ldots,\, u_t^j,\, \ldots], \qquad \mathbf{x}^j = [x_0^j,\, x_1^j,\, \ldots,\, x_t^j,\, \ldots].$$

Il pedice è il tempo, l'apice è l'iterazione: x_t^j è lo stato *realizzato* (misurato, non predetto) all'istante t dell'iterazione j. Tutte le iterazioni partono dallo stesso stato ([P-4]):

$$x_0^j = x_S \qquad \forall j \geq 0. \tag{9}$$

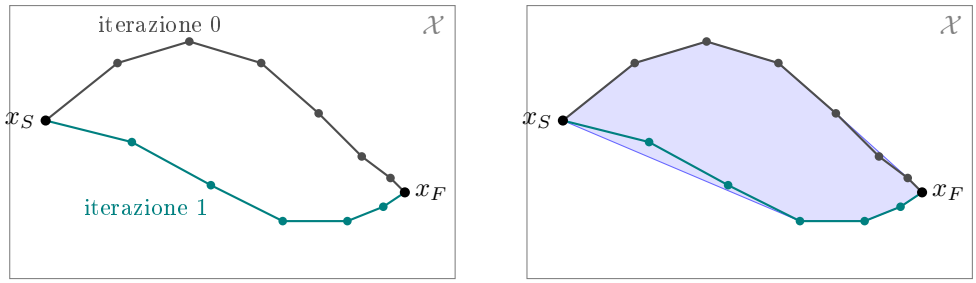
Obiettivo. A ogni iterazione si vorrebbe risolvere il problema a orizzonte infinito (4) ([P-5]) a partire da x_S. Sul costo di stadio il paper fa tre ipotesi ([P-6]):

- h è continuo;
- h è congiuntamente convesso in (x, u);
- h è definito positivo rispetto a $(x_F, 0)$: $h(x_F, 0) = 0$ e $h(x, u) > 0$ per ogni $(x, u) \neq (x_F, 0)$.[1]

Lo stato finale x_F è un equilibrio ammissibile del sistema non forzato, $x_F = Ax_F$ ([P-7]). La positività di h ha una conseguenza importante: un costo totale finito $\sum_t h(x_t, u_t) < \infty$ è possibile solo se $h(x_t, u_t) \to 0$, cioè se la traiettoria converge a x_F. In altre parole, *minimizzare il costo a orizzonte infinito significa anche portare il sistema a* x_F: il compito "arrivare a x_F" è codificato nel costo.

Che cosa si misura a ogni iterazione. Il problema (4) non si sa risolvere direttamente (è a orizzonte infinito e vincolato). Il LMPC lo affronta per approssimazioni successive: a ogni iterazione applica un controllore, registra la traiettoria e il costo effettivamente pagato, e usa questa informazione per l'iterazione successiva. La qualità di un'iterazione si giudica dal costo realizzato $J^j_{0\to\infty}(x_S) = \sum_{t\geq 0} h(x_t^j, u_t^j)$, definito nella sezione 5. Il traguardo è che questo costo scenda iterazione dopo iterazione fino al valore ottimo $J^*_{0\to\infty}(x_S)$.

[1] Il paper scrive "$h(x_t^j, u_t^j) \succ 0$ per ogni $x_t^j \in \mathbb{R}^n \setminus \{x_F\}$, $u_t^j \in \mathbb{R}^m \setminus \{0\}$"; il senso inteso, quello usato nelle dimostrazioni, è la positività per ogni coppia diversa da $(x_F, 0)$.



$\mathcal{SS}^1$: i punti $\qquad$ $\mathcal{CS}^1 = \mathrm{Conv}(\mathcal{SS}^1)$

Figura 3: Spazio di stato (schematico, $n = 2$). A sinistra: gli stati visitati in due iterazioni riuscite formano il safe set campionato $\mathcal{SS}^1$, un insieme finito di punti. A destra: il safe set convesso $\mathcal{CS}^1$ è il loro inviluppo convesso. Il rettangolo rappresenta i vincoli di stato $\mathcal{X}$.

4 L'insieme terminale imparato: il safe set

4.1 Il safe set campionato

Si chiama *iterazione riuscita* un'iterazione la cui traiettoria converge a x_F. L'insieme degli indici delle iterazioni riuscite fino alla j-esima è ([P-9])

$$\mathcal{M}^j = \Big\{ i \in \{0, \dots, j\} : \lim_{s \to \infty} x_s^i = x_F \Big\}. \tag{10}$$

Il *safe set campionato* è l'insieme di tutti gli stati visitati durante le iterazioni riuscite ([P-8]):

$$\mathcal{SS}^j = \bigcup_{i \in \mathcal{M}^j} \bigcup_{s=0}^{\infty} \{x_s^i\}. \tag{11}$$

Proposizione 4.1. *Ogni punto di $\mathcal{SS}^j$ è "sicuro": da $x_s^i \in \mathcal{SS}^j$ esiste una sequenza di ingressi ammissibili che porta lo stato a x_F rispettando i vincoli e restando in $\mathcal{SS}^j$. Inoltre $\mathcal{SS}^j$ è controllo-invariante.*

Dimostrazione. La sequenza è quella registrata, $u_s^i, u_{s+1}^i, \dots$: è già stata applicata con successo, rispetta i vincoli, porta in $x_{s+1}^i, x_{s+2}^i, \dots$, che appartengono tutti a $\mathcal{SS}^j$, e converge a x_F perché $i \in \mathcal{M}^j$. □

Si noti che per sapere che questi punti sono sicuri non serve calcolare nulla: lo sono *perché sono già stati percorsi*. È un insieme controllo-invariante ottenuto gratuitamente dai dati, senza le difficili procedure di calcolo degli insiemi invarianti.

Il difetto di $\mathcal{SS}^j$ è che è un *insieme discreto*. Usarlo come insieme terminale significa imporre $x_{t+N|t} \in \mathcal{SS}^j$, cioè che lo stato finale predetto coincida con uno dei punti memorizzati. Nel LMPC non lineare del 2016 questo vincolo si scrive con una variabile binaria δ_s^i per ogni punto:

$$x_{t+N|t} = \sum_{i,s} \delta_s^i \, x_s^i, \qquad \delta_s^i \in \{0, 1\}, \qquad \sum_{i,s} \delta_s^i = 1,$$

e il problema diventa un MIP con tante variabili binarie quanti sono i punti memorizzati.

4.2 Il safe set convesso

L'idea del paper è *rilassare* le variabili binarie in variabili continue $\lambda_s^i \in [0, 1]$. Lo stato finale non deve più coincidere con un punto memorizzato, ma può essere una qualunque loro combinazione convessa. Si definisce così il *safe set convesso* ([P-10]):

$$\mathcal{CS}^j = \mathrm{Conv}(\mathcal{SS}^j) = \Big\{ \sum_{i \in \mathcal{M}^j} \sum_{s \geq 0} \lambda_s^i x_s^i \;:\; \lambda_s^i \geq 0, \; \sum_{i \in \mathcal{M}^j} \sum_{s \geq 0} \lambda_s^i = 1 \Big\}. \tag{12}$$

(Il paper scrive la stessa cosa numerando i punti di $\mathcal{SS}^j$ come $z_1, z_2, \ldots$ con pesi $\alpha_1, \alpha_2, \ldots$.) Per un sistema non lineare questo rilassamento sarebbe pericoloso: un punto "in mezzo" a punti sicuri non è necessariamente sicuro. Per un sistema lineare invece lo è.

Proposizione 4.2 ($\mathcal{CS}^j$ è controllo-invariante)**.** *Se $\mathcal{X}$ e $\mathcal{U}$ sono convessi, $\mathcal{CS}^j \subseteq \mathcal{X}$ ed è controllo-invariante. Più precisamente, se $x = \sum_{i,s} \lambda_s^i x_s^i \in \mathcal{CS}^j$, l'ingresso*

$$\bar{u} = \sum_{i,s} \lambda_s^i u_s^i \tag{13}$$

è ammissibile e porta in

$$Ax + B\bar{u} = \sum_{i,s} \lambda_s^i x_{s+1}^i \in \mathcal{CS}^j. \tag{14}$$

Dimostrazione. $\mathcal{CS}^j \subseteq \mathcal{X}$ perché $\mathcal{X}$ è convesso e contiene tutti i punti di $\mathcal{SS}^j$. Il resto è il lemma 2.5 applicato alle traiettorie memorizzate: $\bar{u} \in \mathcal{U}$ perché combinazione convessa di ingressi ammissibili; per linearità $Ax + B\bar{u} = \sum \lambda_s^i (Ax_s^i + Bu_s^i) = \sum \lambda_s^i x_{s+1}^i$; questo è una combinazione convessa con gli *stessi pesi* dei punti successori x_{s+1}^i, che appartengono anch'essi a $\mathcal{SS}^j$; quindi sta in $\mathcal{CS}^j$. □

La dimostrazione dice qualcosa di più dell'invarianza: *insegna come restare nell'insieme.* Se uno stato è una media pesata di stati memorizzati, si applica la stessa media pesata degli ingressi memorizzati, e lo stato successivo sarà la stessa media pesata degli stati successivi. Ripetendo all'infinito, lo stato segue la "traiettoria media", che converge a x_F perché tutte le traiettorie componenti vi convergono.

Osservazione 4.3 (Monotonia). Un'iterazione riuscita resta riuscita: $\mathcal{M}^i \subseteq \mathcal{M}^j$ per $i \leq j$. Quindi $\mathcal{SS}^i \subseteq \mathcal{SS}^j$ e ([P-11])

$$\mathcal{CS}^i \subseteq \mathcal{CS}^j \qquad \forall i \leq j. \tag{15}$$

L'insieme terminale può solo crescere con le iterazioni. Ogni nuova traiettoria che esce dall'inviluppo attuale lo allarga.

Osservazione 4.4 (L'equilibrio finale). x_F è il limite delle traiettorie memorizzate. Nella pratica le traiettorie sono finite e si memorizza come ultimo punto x_F stesso (con ingresso $u = 0$ e successore ancora x_F), così che $x_F \in \mathcal{SS}^j$. Si assume questo nel seguito.

5 Il costo terminale imparato: la funzione baricentrica

5.1 Costi realizzati

Il secondo ingrediente è il costo terminale. Per ogni stato memorizzato x_s^i si conosce il costo che è stato *effettivamente pagato* da lì in poi lungo l'iterazione i ([P-12]):

$$J_{s\to\infty}^i(x_s^i) = \sum_{l=0}^{\infty} h(x_{s+l}^i, u_{s+l}^i). \tag{16}$$

È un numero, non una funzione da ottimizzare. Si calcola a ritroso a fine iterazione con la ricorsione

$$J_{s\to\infty}^i(x_s^i) = h(x_s^i, u_s^i) + J_{s+1\to\infty}^i(x_{s+1}^i), \tag{17}$$

partendo dal fondo della traiettoria, dove lo stato è x_F e il costo residuo è nullo. Il costo dell'iterazione i è il cost-to-go dal suo primo stato ([P-13]): $J_{0\to\infty}^i(x_0^i) = J_{0\to\infty}^i(x_S)$.

Poiché ogni traiettoria memorizzata è ammissibile, il suo costo non può essere inferiore all'ottimo:

$$J_{s\to\infty}^i(x_s^i) \;\geq\; J_{0\to\infty}^*(x_s^i). \tag{18}$$

Il cost-to-go realizzato è quindi una *stima per eccesso* del costo ottimo, disponibile però solo nei punti memorizzati.

5.2 La funzione baricentrica

Per avere un costo terminale definito su tutto $\mathcal{CS}^j$ e non solo nei punti memorizzati, il paper interpola i costi realizzati. La *funzione baricentrica* (Jones e Morari, 2010) è ([P-14]–[P-15])

$$P^j(x) = \begin{cases} p^{j,*}(x) & \text{se } x \in \mathcal{CS}^j, \\ +\infty & \text{se } x \notin \mathcal{CS}^j, \end{cases} \tag{19}$$

dove $p^{j,*}(x)$ è il valore ottimo del programma lineare

$$\begin{aligned} p^{j,*}(x) = \min_{\lambda_s^i \geq 0} \; & \sum_{i \in \mathcal{M}^j} \sum_{s \geq 0} \lambda_s^i \, J_{s \to \infty}^i(x_s^i) \\ \text{s.t.} \; & \sum_{i \in \mathcal{M}^j} \sum_{s \geq 0} \lambda_s^i = 1, \qquad \sum_{i \in \mathcal{M}^j} \sum_{s \geq 0} \lambda_s^i x_s^i = x. \end{aligned} \tag{20}$$

In parole: *tra tutti i modi di scrivere x come media pesata di stati memorizzati, si sceglie quello per cui la stessa media pesata dei costi realizzati è minima.* Il valore $+\infty$ fuori da $\mathcal{CS}^j$ è un modo compatto di dire che lo stato finale predetto *deve* cadere in $\mathcal{CS}^j$: in qualunque problema di minimo, un costo infinito equivale a un vincolo.

Osservazione 5.1 (Interpretazione geometrica). Si considerino i punti $(x_s^i,\, J_{s\to\infty}^i) \in \mathbb{R}^{n+1}$: ogni stato memorizzato "sollevato" all'altezza del suo costo. Il grafico di P^j è il *bordo inferiore dell'inviluppo convesso* di questa nuvola di punti (figura 4). È una funzione affine a tratti: sopra ogni "faccia" inferiore dell'inviluppo, P^j interpola linearmente i costi dei vertici della faccia. I punti che stanno sopra questo bordo (stati memorizzati con un costo realizzato "cattivo") non influenzano P^j.

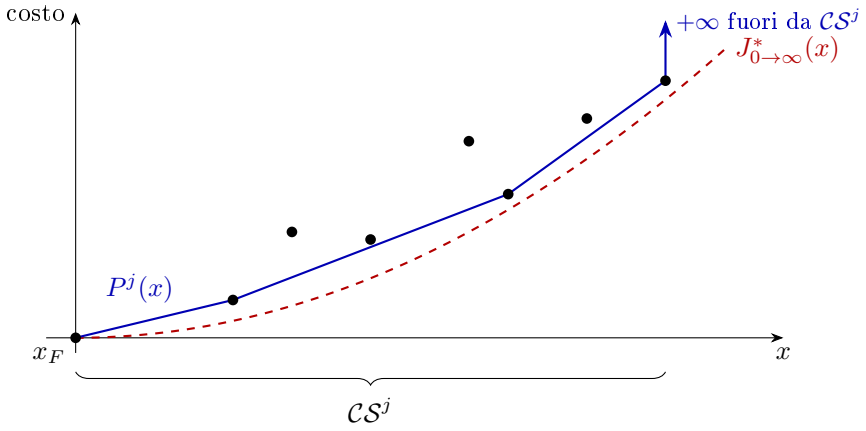


Figura 4: Funzione baricentrica in una dimensione (schematico). I punti neri sono le coppie $(x_s^i, J_{s\to\infty}^i)$: stato memorizzato e costo realizzato da lì in poi. P^j (linea continua) è il bordo inferiore del loro inviluppo convesso, definito su $\mathcal{CS}^j$. La funzione valore ottima $J^*_{0\to\infty}$ (tratteggiata) sta sempre sotto: P^j è una stima per eccesso del costo ottimo.

Il paper osserva ([P-16]) che, indicando con $\lambda_s^{*,i}$ i pesi ottimi del problema (20), si può scrivere

$$P^j(x) = \sum_{i,s} \lambda_s^{*,i} J_{s\to\infty}^i(x_s^i) = \sum_{i,s} \lambda_s^{*,i} \sum_{l=0}^{\infty} h(x_{s+l}^i, u_{s+l}^i), \tag{21}$$

cioè $P^j(x)$ è la media pesata, con i pesi ottimi, dei costi pagati lungo le traiettorie che "passano attorno" a x.

5.3 Proprietà della funzione baricentrica

Proposizione 5.2. *La funzione P^j ha le proprietà seguenti.*

(a) È convessa *su $\mathcal{CS}^j$.*

(b) Sovrastima il costo ottimo*: $P^j(x) \geq J^*_{0\to\infty}(x)$ per ogni $x \in \mathcal{CS}^j$.*

(c) Non supera il costo realizzato *nei punti memorizzati: $P^j(x^i_s) \leq J^i_{s\to\infty}(x^i_s)$.*

(d) Non cresce con le iterazioni*: $P^j(x) \leq P^{j-1}(x)$ per ogni x.*

(e) $P^j(x_F) = 0$ e $P^j(x) \geq 0$.

Dimostrazione. (a) Siano $x_1, x_2 \in \mathcal{CS}^j$ con pesi ottimi λ_1, λ_2 e sia $\theta \in [0,1]$. I pesi $\theta\lambda_1 + (1-\theta)\lambda_2$ sono non negativi, sommano a uno e ricostruiscono $\theta x_1 + (1-\theta)x_2$: sono ammissibili per (20) in quel punto, con costo $\theta P^j(x_1) + (1-\theta)P^j(x_2)$. Il minimo non può essere maggiore, quindi $P^j(\theta x_1 + (1-\theta)x_2) \leq \theta P^j(x_1) + (1-\theta)P^j(x_2)$. (È un fatto generale: il valore ottimo di un LP in funzione del termine noto dei vincoli di uguaglianza è convesso.)

(b) Con i pesi ottimi λ^* per x, si combinano le traiettorie memorizzate che partono dai punti x^i_s, ciascuna "riavviata" all'istante s. Per il lemma 2.5 la combinazione è una traiettoria ammissibile che parte da x, con costo non maggiore di $\sum \lambda^{*,i}_s J^i_{s\to\infty} = P^j(x)$. Il costo ottimo $J^*_{0\to\infty}(x)$ non supera il costo di nessuna traiettoria ammissibile.

(c) Nel punto x^i_s basta scegliere $\lambda^i_s = 1$ e tutti gli altri pesi nulli: è ammissibile e ha costo $J^i_{s\to\infty}(x^i_s)$.

(d) Passando da $j-1$ a j si aggiungono punti e quindi variabili λ al problema (20); i vecchi pesi restano ammissibili (con i nuovi pesi a zero) e il minimo può solo diminuire. Fuori da $\mathcal{CS}^{j-1}$ il valore passa da $+\infty$ a un valore finito o resta $+\infty$.

(e) Tutti i costi realizzati sono non negativi, quindi $P^j \geq 0$; in x_F si sceglie il peso unitario sul punto memorizzato x_F, che ha costo residuo nullo. □

La proprietà più importante è però la seguente: P^j soddisfa su $\mathcal{CS}^j$ esattamente la condizione (7) richiesta al costo terminale di un MPC. Il paper la dimostra dentro la prova del teorema 1 ([P-30]–[P-31]); qui la si isola come lemma.

Lemma 5.3 (P^j è una funzione di Lyapunov di controllo su $\mathcal{CS}^j$)**.** *Sia $x \in \mathcal{CS}^j$ e siano $\lambda^{*,i}_s$ i pesi ottimi di (20) in x. Con l'ingresso $\bar u = \sum_{i,s} \lambda^{*,i}_s u^i_s \in \mathcal{U}$ e lo stato successivo $\bar x = Ax + B\bar u \in \mathcal{CS}^j$ vale*

$$P^j(\bar x) \leq P^j(x) - h(x, \bar u). \tag{22}$$

Dimostrazione. Che $\bar u \in \mathcal{U}$ e $\bar x = \sum \lambda^{*,i}_s x^i_{s+1} \in \mathcal{CS}^j$ è la proposizione 4.2. Per la disuguaglianza, si parte dalla definizione e si usa la ricorsione (17):

$$\begin{aligned}
P^j(x) &= \sum_{i,s} \lambda^{*,i}_s J^i_{s\to\infty}(x^i_s) = \sum_{i,s} \lambda^{*,i}_s h(x^i_s, u^i_s) + \sum_{i,s} \lambda^{*,i}_s J^i_{s+1\to\infty}(x^i_{s+1}) \\
&\geq h\Big(\sum_{i,s} \lambda^{*,i}_s x^i_s,\ \sum_{i,s} \lambda^{*,i}_s u^i_s\Big) + \sum_{i,s} \lambda^{*,i}_s J^i_{s+1\to\infty}(x^i_{s+1}) \qquad \text{(Jensen)} \\
&= h(x, \bar u) + \sum_{i,s} \lambda^{*,i}_s J^i_{s+1\to\infty}(x^i_{s+1}) \\
&\geq h(x, \bar u) + P^j(\bar x).
\end{aligned}$$

L'ultimo passaggio vale perché i pesi $\lambda^{*,i}_s$, "spostati" sui punti successori x^i_{s+1}, sono ammissibili per il problema (20) nel punto $\bar x$: sono non negativi, sommano a uno e ricostruiscono $\bar x$. Il loro costo è quindi maggiore o uguale al minimo $P^j(\bar x)$. □

Idea chiave. Il lemma 5.3 è il cuore tecnico del paper. Combinando le traiettorie memorizzate con i pesi che definiscono $P^j(x)$, si ottiene un ingresso che resta in $\mathcal{CS}^j$ e fa diminuire P^j almeno del costo di stadio. Quindi la coppia $(\mathcal{CS}^j, P^j)$ soddisfa l'ipotesi 2.10 del teorema classico dell'MPC, *senza averla progettata*: è stata raccolta dai dati.

5.4 Iterazioni di durata finita

Nella pratica ogni iterazione dura un tempo finito t_i (*Remark 3* del paper): le somme infinite su s in (12) e (20) diventano somme fino a t_i ([P-17]), e il problema (20) diventa un LP con un numero finito di variabili, una per ogni stato memorizzato. Se l'ultimo stato registrato è (numericamente) x_F, le proprietà precedenti continuano a valere; il criterio usato nell'esempio per decidere quando un'iterazione è finita è discusso nella sezione 9.

6 Il controllore LMPC

6.1 Il problema risolto a ogni istante

All'istante t dell'iterazione j, misurato lo stato x_t^j, il LMPC risolve ([P-18])

$$
\begin{aligned}
J^{\mathrm{LMPC},j}_{t\to t+N}(x_t^j) = \min_{u_{t|t},\dots,u_{t+N-1|t}} \; & \sum_{k=t}^{t+N-1} h(x_{k|t}, u_{k|t}) + P^{j-1}(x_{t+N|t}) \\
\text{s.t.} \quad & x_{k+1|t} = Ax_{k|t} + Bu_{k|t}, \quad k = t,\dots,t+N-1, \\
& x_{t|t} = x_t^j, \\
& x_{k|t} \in \mathcal{X},\ u_{k|t} \in \mathcal{U}, \quad k = t,\dots,t+N-1, \\
& x_{t+N|t} \in \mathcal{CS}^{j-1}.
\end{aligned}
\tag{23}
$$

È esattamente il problema MPC (6) con

$$
\mathcal{X}_f = \mathcal{CS}^{j-1}, \qquad V_f = P^{j-1} :
$$

insieme e costo terminale sono quelli costruiti con le iterazioni $0,\dots,j-1$, cioè con tutti i dati disponibili all'inizio dell'iterazione j. Indicate con

$$
\mathbf{u}^{*,j}_{t:t+N|t} = [u^{*,j}_{t|t},\dots,u^{*,j}_{t+N-1|t}], \qquad \mathbf{x}^{*,j}_{t:t+N|t} = [x^{*,j}_{t|t},\dots,x^{*,j}_{t+N|t}]
$$

la sequenza ottima di ingressi e la traiettoria predetta corrispondente ([P-19]), al sistema si applica il primo ingresso ([P-20]):

$$
u_t^j = u^{*,j}_{t|t}. \tag{24}
$$

All'istante $t+1$ si misura x_{t+1}^j e si risolve di nuovo (23): è un normale orizzonte recedente. Insieme e costo terminale restano *fissi per tutta l'iterazione* j; vengono aggiornati solo alla fine dell'iterazione, quando la nuova traiettoria è completa e i suoi costi realizzati si possono calcolare con la (17).

Un aspetto da sottolineare: il vincolo terminale riguarda solo $x_{t+N|t}$. Gli stati intermedi della predizione possono uscire da $\mathcal{CS}^{j-1}$ (purché restino in $\mathcal{X}$). È così che il LMPC *esplora*: può percorrere regioni dello spazio di stato mai visitate, a patto di rientrare, entro N passi, in una zona di cui si sa che è sicura e quanto costa (figura 5). La traiettoria nuova verrà memorizzata e allargherà l'insieme terminale per le iterazioni successive.

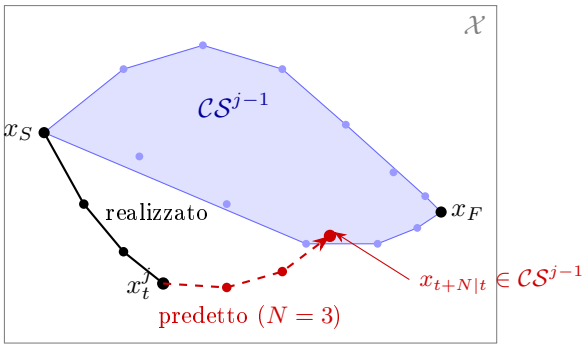


Figura 5: Il problema LMPC all'istante t dell'iterazione j (schematico). La traiettoria predetta (tratteggiata) può uscire dal safe set convesso $\mathcal{CS}^{j-1}$, ma deve rientrarvi entro N passi. Il costo dello stato finale predetto è valutato con P^{j-1}.

6.2 Perché è un problema convesso

Nel problema (23) compare P^{j-1}, che è a sua volta il valore ottimo di un problema di minimo. Poiché si minimizza in entrambi i casi, i due problemi si fondono in uno solo, in cui i pesi λ diventano variabili di decisione insieme agli ingressi. Si indichino con $\mathbf{D}^{j-1}$ la *matrice dei dati*, le cui colonne sono gli stati memorizzati x_s^i, e con $\mathbf{c}^{j-1}$ il vettore dei corrispondenti costi realizzati $J^i_{s\to\infty}(x_s^i)$, per $i \in \mathcal{M}^{j-1}$:

$$\mathbf{D}^{j-1} = \begin{bmatrix} x_0^0 & x_1^0 & \cdots & x_{t_{j-1}}^{j-1} \end{bmatrix} \in \mathbb{R}^{n\times M}, \qquad \mathbf{c}^{j-1} = \begin{bmatrix} J^0_{0\to\infty} & J^0_{1\to\infty} & \cdots \end{bmatrix}^\top \in \mathbb{R}^M,$$

con M numero totale di stati memorizzati. Il problema (23) equivale a

$$\begin{aligned} \min_{u_{t|t},\dots,u_{t+N-1|t},\ \lambda\in\mathbb{R}^M} \quad & \sum_{k=t}^{t+N-1} h(x_{k|t}, u_{k|t}) + (\mathbf{c}^{j-1})^\top \lambda \\ \text{s.t.} \quad & x_{k+1|t} = Ax_{k|t} + Bu_{k|t}, \quad x_{t|t} = x_t^j, \\ & x_{k|t} \in \mathcal{X},\ u_{k|t} \in \mathcal{U}, \\ & x_{t+N|t} = \mathbf{D}^{j-1}\lambda, \qquad \lambda \geq 0, \qquad \mathbf{1}^\top\lambda = 1. \end{aligned} \tag{25}$$

Se h è quadratico e $\mathcal{X}, \mathcal{U}$ sono poliedri:

- il costo è quadratico negli ingressi (e negli stati, che ne sono funzioni affini) e *lineare* nei pesi λ;
- tutti i vincoli sono lineari: la dinamica, i limiti, il legame $x_{t+N|t} = \mathbf{D}^{j-1}\lambda$, la positività e la somma unitaria dei pesi.

È quindi un QP. In forma *condensata*, sostituendo la dinamica, lo stato finale predetto è $x_{t+N|t} = A^N x_t^j + \sum_{l=0}^{N-1} A^{N-1-l} B u_{t+l|t}$, e il vincolo terminale diventa un vincolo di uguaglianza lineare tra ingressi e pesi:

$$\begin{bmatrix} A^{N-1}B & A^{N-2}B & \cdots & B \end{bmatrix} \begin{bmatrix} u_{t|t} \\ \vdots \\ u_{t+N-1|t} \end{bmatrix} - \mathbf{D}^{j-1}\lambda = -A^N x_t^j.$$

L'insieme terminale non viene mai calcolato in forma esplicita (le sue facce): è descritto implicitamente dalle colonne di $\mathbf{D}^{j-1}$.

Osservazione 6.1 (Remark 4 del paper). Il paper sottolinea che il problema (23) è convesso perché l'insieme terminale $\mathcal{CS}^{j-1}$ è convesso e il costo terminale P^{j-1} è una funzione convessa (proposizione 5.2(a)), e indica questa formulazione convessa come il contributo principale rispetto al LMPC del 2016. (Nel testo del Remark 4 i riferimenti [P-18a] e [P-18e] sono scambiati: il vincolo terminale è [P-18e], il costo terminale compare in [P-18a].)

Osservazione 6.2 (Dimensione del problema). Il numero di variabili λ è il numero di stati memorizzati, che cresce a ogni iterazione. Rispetto al MIP del 2016 il vantaggio è enorme (un QP con molte variabili continue si risolve in tempo polinomiale, un MIP con molte variabili binarie no), ma il problema continua a crescere. Nella pratica si usano solo sottoinsiemi dei dati (ad esempio le ultime iterazioni, o i punti vicini allo stato corrente); il paper non tratta questo aspetto.

6.3 L'iterazione zero

All'iterazione $j = 1$ il problema (23) usa $\mathcal{CS}^0$ e P^0, costruiti con la sola iterazione 0. Serve quindi che esista almeno una prima traiettoria buona.

Ipotesi 6.3 (Assumption 1 del paper)**.** È disponibile una traiettoria $\mathbf{x}^0$ dell'iterazione 0, con ingressi $\mathbf{u}^0$, che parte da x_S, rispetta i vincoli e converge a x_F. Di conseguenza $0 \in \mathcal{M}^0$ e $\mathcal{CS}^0$ non è vuoto.

La traiettoria iniziale non deve essere buona, deve solo essere *ammissibile*: può venire da un controllore semplice e conservativo, da una manovra lenta, perfino da una dimostrazione manuale. Da lì in poi è il LMPC a migliorare.

6.4 Lo schema complessivo

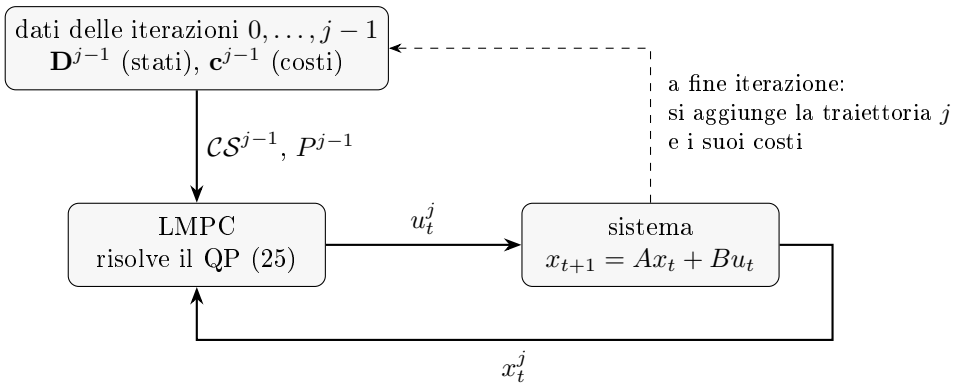


Figura 6: Schema del LMPC. Dentro un'iterazione è un MPC con insieme e costo terminali fissi. Tra un'iterazione e l'altra i dati vengono aggiornati.

Algoritmo LMPC (sistemi lineari).

1. *Inizializzazione.* Si esegue l'iterazione 0 con un controllore qualsiasi che porti da x_S a x_F nel rispetto dei vincoli. Si memorizzano stati e ingressi e si calcolano i costi realizzati con la (17).
2. *Iterazione* $j = 1, 2, \ldots$: si pone $t = 0$, $x_0^j = x_S$; finché l'iterazione non è conclusa:
   (a) si misura x_t^j;
   (b) si risolve il QP (25) con i dati delle iterazioni $0, \ldots, j-1$;
   (c) si applica $u_t^j = u_{t|t}^{*,j}$ e si pone $t \leftarrow t+1$.
3. *Aggiornamento.* Si aggiungono a $\mathbf{D}$ gli stati dell'iterazione j e a $\mathbf{c}$ i loro costi realizzati, calcolati a ritroso. Si passa all'iterazione $j+1$.

7 Fattibilità ricorsiva e stabilità

Teorema 7.1 (Teorema 1 del paper)**.** *Si consideri il sistema* (1) *controllato dal LMPC* (23), (24)*, con* $\mathcal{CS}^j$ *definito da* (12)*, e valga l'ipotesi 6.3. Allora, per ogni iterazione* $j \geq 1$*:*

1. *il problema* (23) *ha soluzione per ogni* $t \in \mathbb{Z}_{\geq 0}$ *(e quindi i vincoli non sono mai violati);*
2. *l'equilibrio* x_F *è asintoticamente stabile per l'anello chiuso* (1), (24)*.*

Il paper scrive che "la dimostrazione segue da argomenti standard di MPC". Alla luce della sezione 2 il motivo è chiaro: è il teorema 2.11 con $(\mathcal{X}_f, V_f) = (\mathcal{CS}^{j-1}, P^{j-1})$, e il lemma 5.3 garantisce che questa coppia soddisfa l'ipotesi 2.10. Conviene comunque seguire i passi del paper, che rendono esplicito il ruolo dei dati.

Passo 1: fattibilità all'istante iniziale ([P-21]–[P-22]). Per la (15), $\mathcal{CS}^0 \subseteq \mathcal{CS}^{j-1}$ per ogni $j \geq 1$, e $\mathcal{CS}^0$ non è vuoto per l'ipotesi 6.3. All'istante $t = 0$ dell'iterazione j lo stato è $x_0^j = x_S = x_0^0$. I primi N passi dell'iterazione zero,

$$[x_0^0,\, x_1^0,\, \ldots,\, x_N^0], \qquad [u_0^0,\, u_1^0,\, \ldots,\, u_{N-1}^0],$$

sono una soluzione ammissibile di (23): partono dallo stato giusto, rispettano dinamica e vincoli (sono stati realizzati) e terminano in $x_N^0 \in \mathcal{SS}^0 \subseteq \mathcal{CS}^0 \subseteq \mathcal{CS}^{j-1}$.

Passo 2: dalla fattibilità in t a quella in $t+1$ ([P-23]–[P-28]). Sia il problema risolto all'istante t, con soluzione ottima $\mathbf{u}_{t:t+N|t}^{*,j}$, $\mathbf{x}_{t:t+N|t}^{*,j}$. Il vincolo terminale dà $x_{t+N|t}^{*,j} \in \mathcal{CS}^{j-1}$; siano $\lambda_s^{*,i}$ i pesi che realizzano $P^{j-1}(x_{t+N|t}^{*,j})$ ([P-24]). Con questi pesi si costruiscono ([P-25]–[P-26])

$$\bar{u} = \sum_{i,s} \lambda_s^{*,i} u_s^i \in \mathcal{U}, \qquad \bar{x} = A x_{t+N|t}^{*,j} + B\bar{u} = \sum_{i,s} \lambda_s^{*,i} x_{s+1}^i \in \mathcal{CS}^{j-1}.$$

Poiché il modello di predizione coincide con il sistema, lo stato realizzato all'istante successivo è quello predetto ([P-27]):

$$x_{t+1}^j = x_{t+1|t}^{*,j}. \tag{26}$$

All'istante $t+1$ la sequenza traslata ([P-28])

$$[u_{t+1|t}^{*,j},\, \ldots,\, u_{t+N-1|t}^{*,j},\, \bar{u}], \qquad [x_{t+1|t}^{*,j},\, \ldots,\, x_{t+N|t}^{*,j},\, \bar{x}]$$

parte dallo stato corretto, rispetta dinamica e vincoli e termina in $\mathcal{CS}^{j-1}$: è ammissibile (figura 7). Per induzione su t, il problema ha soluzione a ogni istante.

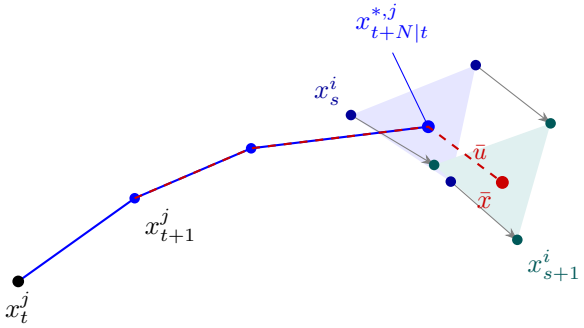


Figura 7: Argomento della traslazione. Lo stato finale predetto all'istante t (blu) è combinazione convessa di alcuni stati memorizzati (triangolo blu). Applicando la stessa combinazione dei loro ingressi si arriva in $\bar{x}$, la stessa combinazione dei loro successori (triangolo verde), che è ancora in $\mathcal{CS}^{j-1}$. La traiettoria rossa tratteggiata è la candidata ammissibile all'istante $t+1$.

Passo 3: il costo ottimo come funzione di Lyapunov ([P-29]–[P-32]). All'interno dell'iterazione j il problema (23) non dipende da t (dinamica, vincoli, $\mathcal{CS}^{j-1}$ e P^{j-1} sono fissi): il suo valore ottimo è una funzione del solo stato, che si indica con $J^{\text{LMPC},j}_{0\to N}(\cdot)$. Si vuole mostrare che è una funzione di Lyapunov per x_F.

- *Positività.* Per $x \neq x_F$ il costo ottimo contiene almeno il termine $h(x, u_{t|t}) > 0$; in x_F la soluzione $u = 0$ mantiene lo stato in $x_F \in \mathcal{CS}^{j-1}$ con costo nullo, quindi $J^{\text{LMPC},j}_{0\to N}(x_F) = 0$.
- *Continuità.* Si dimostra come in Mayne et al. (2000); il paper non entra nei dettagli.
- *Decrescita.* Si scrive il costo ottimo in t separando il primo termine e sviluppando P^{j-1} con la (21) ([P-30]); con la disuguaglianza di Jensen e la definizione di P^{j-1} come minimo, esattamente come nel lemma 5.3, si ottiene ([P-31])

$$J^{\text{LMPC},j}_{0\to N}(x^j_t) \geq h(x^j_t, u^j_t) + \underbrace{\sum_{k=t+1}^{t+N-1} h(x^{*,j}_{k|t}, u^{*,j}_{k|t}) + h(x^{*,j}_{t+N|t}, \bar{u}) + P^{j-1}(\bar{x})}_{\text{costo della candidata in } t+1}$$
$$\geq h(x^j_t, u^j_t) + J^{\text{LMPC},j}_{0\to N}(x^j_{t+1}).$$

  L'ultima disuguaglianza vale perché il costo ottimo in $t+1$ non supera quello della candidata ammissibile del passo 2.

Si ottiene così ([P-32])

$$J^{\text{LMPC},j}_{0\to N}(x^j_{t+1}) - J^{\text{LMPC},j}_{0\to N}(x^j_t) \leq -h(x^j_t, u^j_t) < 0 \qquad \forall x^j_t \neq x_F, \tag{27}$$

e il teorema di Lyapunov dà la stabilità asintotica di x_F.

Osservazione 7.2 (Regione di attrazione). Il LMPC all'iterazione j funziona da ogni stato da cui sia possibile entrare in $\mathcal{CS}^{j-1}$ in N passi rispettando i vincoli. Nel linguaggio del libro è l'*insieme controllabile in N passi* $K_N(\mathcal{CS}^{j-1})$ (sezione 10.2). Poiché $\mathcal{CS}^{j-1}$ cresce con j, cresce anche questa regione: le iterazioni non migliorano solo il costo, ma anche l'insieme degli stati da cui il controllore è in grado di operare.

8 Miglioramento e ottimalità

8.1 Il costo non peggiora da un'iterazione all'altra

Teorema 8.1 (Teorema 2 del paper)**.** *Nelle ipotesi del teorema 7.1, il costo di ogni iterazione non supera quello della precedente:*

$$J^{j}_{0\to\infty}(x_S) \le J^{j-1}_{0\to\infty}(x_S) \qquad \forall j \ge 1.$$

Il paper rimanda la dimostrazione al lavoro del 2016. Con gli strumenti di questo documento la si ricostruisce in due passaggi.

Prima disuguaglianza: il costo predetto in x_S non supera il costo dell'iterazione precedente. L'iterazione $j-1$ è riuscita (teorema 7.1 o ipotesi 6.3 se $j=1$), quindi i suoi dati sono in $\mathcal{CS}^{j-1}$. I suoi primi N passi sono una soluzione ammissibile di (23) in x_S (come nel passo 1 del teorema 7.1). Il loro costo, usando la proposizione 5.2(c), è

$$\sum_{k=0}^{N-1} h(x^{j-1}_k, u^{j-1}_k) + P^{j-1}(x^{j-1}_N) \le \sum_{k=0}^{N-1} h(x^{j-1}_k, u^{j-1}_k) + J^{j-1}_{N\to\infty}(x^{j-1}_N) = J^{j-1}_{0\to\infty}(x_S).$$

Il costo ottimo non supera quello di una soluzione ammissibile: $J^{\mathrm{LMPC},j}_{0\to N}(x_S) \le J^{j-1}_{0\to\infty}(x_S)$.

Seconda disuguaglianza: il costo realizzato non supera il costo predetto. Sommando la (27) da $t=0$ a $t=T$ i termini si cancellano a due a due (somma telescopica):

$$\sum_{t=0}^{T} h(x^j_t, u^j_t) \le J^{\mathrm{LMPC},j}_{0\to N}(x^j_0) - J^{\mathrm{LMPC},j}_{0\to N}(x^j_{T+1}) \le J^{\mathrm{LMPC},j}_{0\to N}(x_S),$$

perché $J^{\mathrm{LMPC},j}_{0\to N} \ge 0$. Per $T\to\infty$: $J^{j}_{0\to\infty}(x_S) \le J^{\mathrm{LMPC},j}_{0\to N}(x_S)$.

Mettendo insieme:

$$J^{*}_{0\to\infty}(x_S) \;\le\; J^{j}_{0\to\infty}(x_S) \;\le\; J^{\mathrm{LMPC},j}_{0\to N}(x_S) \;\le\; J^{j-1}_{0\to\infty}(x_S). \tag{28}$$

La prima disuguaglianza vale perché la traiettoria dell'iterazione j è ammissibile per il problema a orizzonte infinito. La successione dei costi di iterazione è quindi *non crescente e limitata inferiormente*: converge sempre a un limite. Il teorema successivo dice qual è.

8.2 La traiettoria limite è ottima

Teorema 8.2 (Teorema 3 del paper)**.** *Nelle ipotesi del teorema 7.1, con $N>1$, si supponga che le traiettorie in anello chiuso convergano, per $j\to\infty$, a una traiettoria stazionaria $\mathbf{x}^\infty = \lim_j \mathbf{x}^j$ con ingressi $\mathbf{u}^\infty = \lim_j \mathbf{u}^j$. Allora $(\mathbf{x}^\infty, \mathbf{u}^\infty)$ è una soluzione ottima globale del problema a orizzonte infinito* (4)*: $\mathbf{x}^\infty = \mathbf{x}^*$, $\mathbf{u}^\infty = \mathbf{u}^*$.*

Anche questa dimostrazione è rimandata al lavoro del 2016; qui se ne dà l'idea, senza pretesa di completezza.

- Quando le iterazioni non cambiano più, la traiettoria stazionaria fa parte dei dati, e lungo di essa il costo terminale coincide con il costo realmente pagato. A ogni istante il LMPC potrebbe scegliere di deviarne per N passi e poi rientrare in $\mathcal{CS}$; se non lo fa, è perché *nessuna modifica di N ingressi consecutivi* migliora il costo. La traiettoria stazionaria è quindi un punto in cui non esistono miglioramenti "locali" (nel senso di modifiche su finestre di N passi).

- Il problema a orizzonte infinito (4), per un sistema lineare con vincoli convessi e costo convesso, è un problema *convesso*. In un problema convesso un punto che non si può migliorare localmente è un ottimo globale (sezione 2.4).

Per sistemi non lineari (il lavoro del 2016) lo stesso ragionamento dà solo un ottimo locale; è la convessità, cioè ancora una volta la linearità del sistema, a renderlo globale. (L'introduzione della sezione 3.3 del paper parla di ottimo "locale", ma l'enunciato del teorema 3 è di ottimalità globale, coerentemente con questa osservazione.)

Due cautele nella lettura del teorema 8.2:

- la convergenza delle traiettorie è un'*ipotesi*, non una tesi: il teorema 8.1 garantisce che i *costi* convergono, ma non che le traiettorie convergano;
- l'ipotesi $N > 1$ è richiesta dalla dimostrazione del 2016; il paper non commenta che cosa possa succedere con $N = 1$.

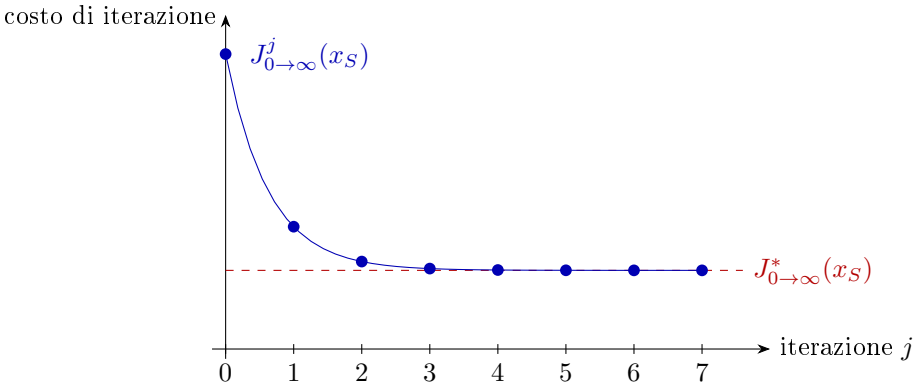


Figura 8: Andamento qualitativo del costo di iterazione previsto dai teoremi 8.1 e 8.2: non cresce mai e, se le traiettorie convergono, tende al costo ottimo a orizzonte infinito. Nell'esempio del paper quasi tutto il miglioramento avviene alla prima iterazione.

9 L'esempio del paper: LQR vincolato

Il problema di prova. Il paper verifica il LMPC su un regolatore lineare quadratico vincolato a orizzonte infinito ([P-33]):

$$\min_{u_0,u_1,\dots} \sum_{k=0}^{\infty} \left(\|x_k\|_2^2 + \|u_k\|_2^2\right), \qquad x_{k+1} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} x_k + \begin{bmatrix} 0 \\ 1 \end{bmatrix} u_k,$$

con $x_0 = x_S$, limiti $-4 \le x_k \le 4$ su ciascuna componente e $-1 \le u_k \le 1$. Il sistema è un *doppio integratore* discreto: la prima componente dello stato è una posizione, la seconda una velocità, l'ingresso un'accelerazione. L'equilibrio è $x_F = 0$, il costo è quadratico e definito positivo, i vincoli sono scatole: tutte le ipotesi del paper sono soddisfatte. La scelta è didattica per un motivo preciso: per questo problema la soluzione ottima esatta a orizzonte infinito si può calcolare (con l'algoritmo di Borrelli, 2003), e quindi si può verificare se il LMPC la trova davvero.

Implementazione. Il LMPC è scritto come QP (sezione 6.2) con YALMIP e risolto con `quadprog`. Per avere iterazioni di durata finita, il paper considera conclusa l'iterazione j al primo istante in cui il costo ottimo predetto scende sotto una soglia piccolissima ([P-34]):

$$t_j = \min\left\{t \in \mathbb{Z}_{\ge 0} : J^{\mathrm{LMPC},j}_{0\to N}(x^j_t) \le \varepsilon\right\},$$

cioè quando lo stato è, a tutti gli effetti, arrivato all'equilibrio. Le somme della funzione baricentrica sono troncate a t_j come in [P-17].

Risultati (lettura qualitativa).

- *Miglioramento monotono* (Table 1 del paper). Il costo di iterazione non cresce mai, come previsto dal teorema 8.1. Il salto più grande avviene alla prima iterazione (la traiettoria iniziale è volutamente non ottima); le iterazioni successive limano differenze sempre più piccole, fino a stabilizzarsi.
- *Convergenza all'ottimo vero* (equazioni [P-36]–[P-39]). La traiettoria stazionaria del LMPC coincide con quella ottima del CLQR calcolata in modo esatto, a meno di errori dell'ordine della precisione numerica, sia come stati sia come costo. È la verifica sperimentale del teorema 8.2.
- *Ruolo dell'orizzonte* (Table 2). Il risultato vale per diversi stati iniziali e diversi orizzonti, anche cortissimi ($N = 2$): un orizzonte corto, accompagnato da un costo terminale imparato, basta a raggiungere l'ottimo a orizzonte *infinito*. Quello che cambia è la velocità: con orizzonte più lungo il controllore ha più libertà di esplorare lo spazio di stato in ogni iterazione, e converge in molte meno iterazioni (decine con $N = 2$, una decina con $N = 4$).
- *Costo computazionale.* Sullo stesso problema, il LMPC convesso converge in decine di secondi, quello del 2016 basato su MIP in ore. È la conferma del contributo principale del paper.

10 Collegamenti con il libro di Borrelli, Bemporad e Morari

Il paper occupa sei pagine e per quasi tutti i risultati di base rimanda ad "argomenti standard di MPC" (Mayne et al., 2000) e a Borrelli (2003). Quegli argomenti sono esposti in modo sistematico nel libro *Predictive Control for Linear and Hybrid Systems* di F. Borrelli, A. Bemporad e M. Morari (2017), indicato qui come [BBM]. Leggere il paper con il libro accanto mostra una cosa importante: **il LMPC non introduce una nuova teoria della stabilità**. Riusa il teorema di stabilità dell'MPC del libro, e sostituisce gli ingredienti terminali, che nel libro sono progettati con il regolatore LQR e con operazioni sui poliedri, con ingredienti ricavati dai dati. Anche lo strumento con cui li ricava, l'interpolazione baricentrica, è nel libro, nel capitolo 13, usato però per uno scopo diverso.

La tabella 2 riassume i collegamenti; le sottosezioni li discutono uno per uno.

Corrispondenza di notazione. Il libro chiama $q(x, u)$ il costo di stadio (qui h), $p(x)$ il costo terminale (qui V_f, e nel LMPC P^{j-1}) e $\mathcal{X}_f$ l'insieme terminale (nel LMPC $\mathcal{CS}^{j-1}$). Il libro usa la lettera P per la *matrice* del costo terminale quadratico $x^\top P x$: non va confusa con la *funzione* P^j del paper. Infine il libro pone l'equilibrio nell'origine, mentre il paper lo chiama x_F; poiché $x_F = Ax_F$, il cambio di variabile $x \mapsto x - x_F$ trasforma il sistema del paper in uno con equilibrio nell'origine, con la stessa dinamica, e i risultati si trasferiscono senza modifiche.

10.1 Il Teorema 1 del paper è il Teorema 12.2 del libro

Il Teorema 12.2 del libro è il risultato di riferimento sulla fattibilità e stabilità dell'MPC: il libro stesso, nella sezione 12.8, lo indica come "il risultato principale" su fattibilità e stabilità e ne fa risalire l'idea a Keerthi e Gilbert. Le sue ipotesi, nella notazione di questo documento, e il modo in cui il LMPC le soddisfa sono:

Tabella 2: Dove si trovano nel libro i concetti usati dal paper.

Nel paper	Nel libro	Che cosa dice il libro
Problema a orizzonte infinito [P-5], CLQR [P-33]	Sez. 7.4, 11.3.4–11.3.5	equazione di Bellman, soluzione esatta del CLQR affine a tratti (Teorema 11.4) e algoritmo per calcolarla, usato dal paper come riferimento
Safe set, invarianza	Def. 10.9–10.13, Teoremi 11.2 e 12.1	insiemi controllabili e invarianti, insiemi ammissibili dell'MPC, fattibilità ricorsiva
Inviluppo convesso [P-10]	Sez. 4.2, 4.4.2	rappresentazioni V e H dei politopi, costo del cambio di rappresentazione
Teorema 1 (stabilità)	Teorema 12.2, Remark 12.2–12.3	ipotesi (A0)–(A3) su insieme e costo terminali, funzione di Lyapunov di controllo
Funzione baricentrica [P-14]–[P-15]	Cap. 13 (Def. 13.1, Lemmi 13.1–13.2, Teorema 13.2)	interpolazione baricentrica, proprietà dell'inviluppo convesso, sovrastima del costo ottimo
Convessità di P^j, Remark 4	Teorema 6.5, Corollario 5.1, Teorema 6.7	la funzione valore di un programma multiparametrico convesso è convessa; per un mp-LP è anche continua e affine a tratti
LMPC non lineare del 2016 (MIP)	Sez. 2.4, 16.4, 17.4	vincoli logici come variabili binarie, MIQP, branch and bound
Esempio: doppio integratore	Esempi 11.1, 11.2, 12.1	lo stesso sistema, usato per insiemi ammissibili, CLQR esplicito e perdita di fattibilità del receding horizon
Limiti: disturbi, incertezze	Sez. 10.3–10.4, Cap. 15	insiemi invarianti robusti, MPC robusto

- **(A0)** costo di stadio e costo terminale continui e definiti positivi. Per h è l'ipotesi [P-6]. Per P^{j-1}: è continua su $\mathcal{CS}^{j-1}$ (sezione 10.4), si annulla in x_F e per $x \neq x_F$ vale $P^{j-1}(x) \geq J^*_{0\to\infty}(x) > 0$ (proposizione 5.2(b)).
- **(A1)** $\mathcal{X}$, $\mathcal{U}$, $\mathcal{X}_f$ chiusi e contenenti l'equilibrio nel loro *interno*: su questo punto si veda l'osservazione qui sotto.
- **(A2)** $\mathcal{X}_f$ controllo-invariante e contenuto in $\mathcal{X}$: è la proposizione 4.2.
- **(A3)** $\min_{v\in\mathcal{U},\, Ax+Bv\in\mathcal{X}_f} \big(-p(x)+q(x,v)+p(Ax+Bv)\big) \leq 0$ per ogni $x \in \mathcal{X}_f$: è il lemma 5.3, con $v = \bar{u}$.

La dimostrazione del libro (equazioni (12.19)–(12.20) di [BBM]) è la stessa del paper ([P-28]–[P-32]): sequenza traslata più un ingresso finale fornito da (A3), confronto con l'ottimo, decrescita del costo ottimo. L'unica parte che il paper deve scrivere esplicitamente è la verifica di (A3), che nel libro è garantita in fase di progetto (con il costo LQR, equazioni (12.24)–(12.26) di [BBM], vale con il segno di uguaglianza) e che nel paper discende dalla disuguaglianza di Jensen applicata ai dati. In questo senso il contributo teorico del paper sta tutto nella sezione 5: mostrare che $(\mathcal{CS}^{j-1}, P^{j-1})$ soddisfa (A2) e (A3).

Il libro contiene anche, nella sezione 7.4.2 (Teorema 7.1), la versione più semplice dello stesso ragionamento, con vincolo terminale $x_N = 0$: la sequenza ottima traslata e completata con ingresso nullo è ammissibile al passo successivo, e il costo ottimo decresce del costo di stadio. È utile leggerla prima del Teorema 12.2, perché isola l'idea della traslazione senza gli ingredienti terminali.

Osservazione 10.1 (L'ipotesi (A1) e l'equilibrio sul bordo di $\mathcal{CS}^{j-1}$). Nel libro (A1) serve a dimostrare la continuità del costo ottimo nell'equilibrio, tramite la disuguaglianza $J^*_0(x) \leq p(x)$ su $\mathcal{X}_f$ (equazione (12.23) di [BBM]). Nel LMPC l'equilibrio x_F è l'ultimo punto di tutte le traiettorie memorizzate e di solito sta sul *bordo* dell'inviluppo convesso, spesso su un vertice (si

veda la figura 3), non al suo interno. La disuguaglianza $J_{0\to N}^{\mathrm{LMPC},j}(x) \le P^{j-1}(x)$ su $\mathcal{CS}^{j-1}$ si ottiene comunque con lo stesso argomento del libro (iterando il lemma 5.3), ma la stabilità va intesa rispetto all'insieme degli stati ammissibili, come nel teorema di Lyapunov del libro (Teorema 7.2, enunciato su un insieme che contiene l'origine, non necessariamente nel suo interno). Il paper non entra in questo dettaglio e rimanda a Mayne et al. per la continuità.

Osservazione 10.2 (Il problema che il LMPC risolve, nelle parole del libro). Nel Remark 12.2 il libro osserva che la procedura del Teorema 12.2 è in generale *conservativa*: introdurre un insieme terminale artificiale riduce la regione di attrazione e può peggiorare le prestazioni. Con la scelta standard ($\mathcal{X}_f$ = massimo insieme invariante del sistema in anello chiuso con il guadagno LQR, costo terminale $x^\top P_\infty x$) l'insieme terminale è un intorno dell'equilibrio in cui i vincoli non sono attivi, di solito piccolo. Il LMPC risponde proprio a questa osservazione: l'insieme terminale non è un intorno piccolo costruito attorno all'equilibrio, ma l'insieme di tutti gli stati da cui si sa già, per esperienza, come arrivare all'equilibrio; e cresce con le iterazioni.

10.2 Insiemi controllabili, invarianti e regione di attrazione

Il capitolo 10 del libro dà il linguaggio preciso per parlare della regione in cui il LMPC funziona. Le definizioni che servono sono:

- l'*insieme predecessore* [BBM, Def. 10.2] $\mathrm{Pre}(S) = \{x : \exists u \in \mathcal{U},\ Ax + Bu \in S\}$, gli stati che possono essere portati in S in un passo;
- l'*insieme controllabile in N passi* [BBM, Def. 10.5], $K_N(S)$, definito ricorsivamente da $K_0(S) = S$ e $K_i(S) = \mathrm{Pre}(K_{i-1}(S)) \cap \mathcal{X}$: gli stati che possono essere portati in S in N passi rispettando i vincoli;
- il *massimo insieme controllo-invariante* $\mathcal{C}_\infty$ [BBM, Def. 10.10], il più grande insieme in cui si può tenere lo stato per sempre rispettando i vincoli;
- per il CLQR, l'insieme $\mathcal{X}_\infty$ degli stati da cui il problema a orizzonte infinito ha costo finito [BBM, eq. (11.44)], che il libro identifica con il massimo insieme stabilizzabile verso l'equilibrio. È il dominio di $J_{0\to\infty}^*$.

Il Teorema 11.2 del libro dice che, se l'insieme terminale $\mathcal{X}_f$ è controllo-invariante, l'insieme degli stati da cui il problema MPC ha soluzione è $K_N(\mathcal{X}_f)$, che è a sua volta controllo-invariante e contenuto in $\mathcal{C}_\infty$. Il Teorema 12.1 ne ricava la fattibilità ricorsiva, *qualunque sia la funzione di costo*. Applicati al LMPC:

- all'iterazione j il LMPC ha soluzione esattamente in $K_N(\mathcal{CS}^{j-1})$, che è controllo-invariante;
- la fattibilità ricorsiva dipende solo da $\mathcal{CS}^{j-1}$, non da P^{j-1}: il costo terminale serve per la stabilità e per il miglioramento, non per la fattibilità;
- poiché ogni punto di $\mathcal{CS}^{j-1}$ ha costo $J_{0\to\infty}^*$ finito (proposizione 5.2(b)), vale la catena di inclusioni
$$\{x_F\} \subseteq \mathcal{CS}^0 \subseteq \mathcal{CS}^{j-1} \subseteq K_N(\mathcal{CS}^{j-1}) \subseteq \mathcal{X}_\infty \subseteq \mathcal{C}_\infty \subseteq \mathcal{X}, \tag{29}$$
illustrata nella figura 9.

Il confronto con il modo in cui il libro calcola questi insiemi è istruttivo. Gli algoritmi 10.2 e 10.3 di [BBM] calcolano $\mathcal{C}_\infty$ e gli insiemi stabilizzabili iterando l'operatore Pre, cioè proiezioni di poliedri in rappresentazione H; in generale non è garantito che terminino in un numero finito di passi, e il costo cresce rapidamente con la dimensione dello stato. Il LMPC ottiene invece, *senza alcuna operazione sugli insiemi*, un sottoinsieme controllo-invariante di $\mathcal{X}_\infty$ in rappresentazione V: i dati stessi ne sono i generatori. È un'approssimazione interna, che dipende da quali regioni dello spazio di stato le iterazioni hanno visitato, ma è disponibile gratuitamente e si allarga da sola.

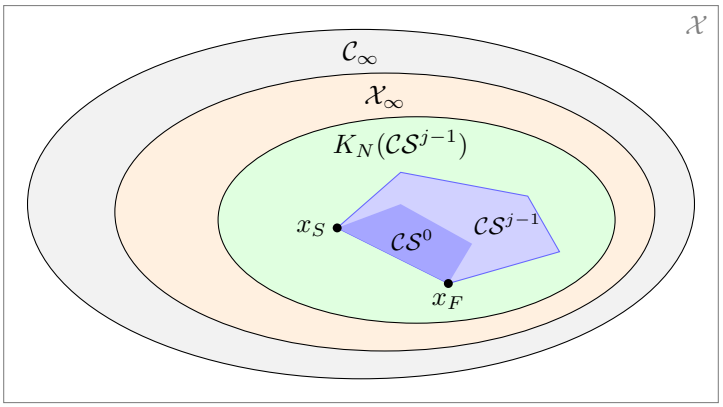


Figura 9: Gli insiemi della catena (29) (schematico). Il safe set convesso cresce con le iterazioni dentro $\mathcal{X}_\infty$, il dominio della funzione valore ottima $J^*_{0\to\infty}$; la regione in cui il LMPC ha soluzione è l'insieme degli stati da cui lo si raggiunge in N passi.

10.3 La funzione baricentrica e il capitolo 13

Il paper attribuisce la funzione baricentrica a Jones e Morari (2010). Il capitolo 13 del libro, scritto da C. N. Jones, espone la stessa teoria nel suo contesto originale: l'*MPC approssimato*. Lì il problema è un altro: si ha già un MPC con buone proprietà, ma risolverlo online, o memorizzarne la soluzione esplicita, costa troppo. Si calcola allora la soluzione ottima $z^*(v)$ in alcuni punti campione $v \in V$ dello spazio di stato e la si interpola nei punti intermedi.

Gli strumenti del capitolo 13.

- [BBM, Def. 13.1]: un insieme di funzioni $w_v(x)$ è *baricentrico* su $\mathrm{Conv}(V)$ se $w_v(x) \geq 0$ (positività), $\sum_v w_v(x) = 1$ (partizione dell'unità) e $\sum_v v\, w_v(x) = x$ (precisione lineare). Sono esattamente i vincoli sui pesi λ nel problema (20) ([P-15b]–[P-15c]).
- [BBM, eq. (13.18)]: la soluzione interpolata è $\tilde{z}(x) = \sum_v w_v(x)\, z^*(v)$.
- [BBM, Lemma 13.1] (*proprietà dell'inviluppo convesso*): la soluzione interpolata è ammissibile in tutto $\mathrm{Conv}(V)$. Il motivo è che i vincoli sono convessi congiuntamente in soluzione e stato: è lo stesso meccanismo del lemma 2.5 e della proposizione 4.2.
- [BBM, Lemma 13.2]: $J^*(x) \leq J(\tilde{z}(x), x) \leq \sum_v w_v(x) J^*(v)$. L'interpolazione dei costi nei campioni sovrastima il costo della soluzione interpolata, che a sua volta sovrastima l'ottimo. È la proposizione 5.2(b), e la figura 13.3 del libro è l'analoga della figura 4.
- [BBM, Teorema 13.2]: per certificare la qualità dell'approssimazione su $\mathrm{Conv}(V)$ si ottimizza "su tutte le possibili funzioni baricentriche", cioè sui pesi $\lambda_v \geq 0$ con $\sum \lambda_v = 1$ e $\sum \lambda_v v = x$. Compare cioè lo stesso minimo sui pesi che definisce P^j nel paper.
- [BBM, Teorema 13.1]: un MPC risolto in modo *subottimo* resta stabile se l'errore di subottimalità è minore del costo di stadio. La dimostrazione è ancora quella della sequenza traslata.

Come il paper usa questi strumenti. La corrispondenza è diretta se si legge ogni stato memorizzato x^i_s come un campione v, e la coda di traiettoria memorizzata che parte da lì, $(u^i_s, u^i_{s+1}, \dots)$, come la "soluzione nel campione". Allora:

- l'ingresso $\bar{u} = \sum \lambda^{*,i}_s u^i_s$ usato nella prova di fattibilità (proposizione 4.2) è l'interpolazione baricentrica (13.18) del primo ingresso delle code memorizzate;

- la prova del Lemma 13.2 non usa l'ottimalità delle soluzioni nei campioni, solo la loro ammissibilità e la convessità del costo; per questo funziona anche con le traiettorie del paper, che sono ammissibili ma non ottime. Al posto del costo ottimo nel campione compare il costo realizzato $J^i_{s\to\infty}$, e si ottiene $P^j \geq J^*_{0\to\infty}$;
- la scelta dei pesi che minimizza il costo interpolato (il programma lineare (20)) è quella che il Teorema 13.2 usa come rilassamento.

Tabella 3: Interpolazione baricentrica nel libro (cap. 13) e nel paper.

	Libro, cap. 13	Paper
Scopo	ridurre il calcolo online, approssimando un MPC già progettato	migliorare le prestazioni, imparando insieme e costo terminali
Campioni	punti scelti offline (triangolazioni, griglie, Algoritmo 13.1)	stati visitati dal sistema in anello chiuso
Valori nei campioni	soluzioni *ottime* $z^*(v)$ e costi ottimi	traiettorie *realizzate* e costi realmente pagati
Pesi	funzioni baricentriche fissate per regione (Def. 13.3, Lemma 13.5)	scelti a ogni istante da un LP che minimizza il costo
Che cosa si interpola	la legge di controllo	il costo terminale (e implicitamente l'ingresso $\bar{u}$)
Garanzia	Teorema 13.1 (MPC subottimo)	Teorema 12.2 di [BBM] / Teorema 1 del paper

10.4 Programmazione multiparametrica: la forma di P^j e di $J^{\mathrm{LMPC},j}_{0\to N}$

La parte II del libro studia i problemi di ottimo in cui un vettore di parametri x entra nei vincoli: i *programmi multiparametrici*. Due risultati si applicano al paper.

P^j è la funzione valore di un mp-LP. Il problema (20) che definisce P^j ha la forma (6.11) di [BBM],

$$\min_z \; c^\top z \quad \text{s.t. } Gz \leq w + Sx,$$

con variabile $z = \lambda$, parametro x, costo $c = \mathbf{c}^j$ (i costi realizzati) e vincoli $\lambda \geq 0$, $\mathbf{1}^\top\lambda = 1$, $\mathbf{D}^j\lambda = x$ (le uguaglianze si scrivono come coppie di disuguaglianze). Il Teorema 6.5 e il Corollario 5.1 del libro dicono che la funzione valore di un mp-LP è *convessa, continua e affine a tratti* sul suo dominio, che qui è $\mathcal{CS}^j$. Si ritrova così, in forma più forte, la proposizione 5.2(a), e si rende rigorosa l'immagine geometrica della figura 4: le *regioni critiche* dell'mp-LP, in cui l'insieme dei pesi attivi non cambia, sono le proiezioni delle facce inferiori dell'inviluppo convesso dei punti $(x^i_s, J^i_{s\to\infty})$, e su ciascuna P^j è affine.

$J^{\mathrm{LMPC},j}_{0\to N}$ è la funzione valore di un programma parametrico convesso. Il problema (25) ha come parametro lo stato misurato x^j_t ed è convesso congiuntamente nelle variabili di decisione e nel parametro. La sua funzione valore $J^{\mathrm{LMPC},j}_{0\to N}$ è quindi convessa: la dimostrazione è la stessa della proposizione 5.2(a) e del Teorema 6.7 del libro (si combinano convessamente le soluzioni ottime in due stati). Il Teorema 6.7 non si applica alla lettera, perché richiede una matrice hessiana definita positiva, mentre qui il costo è lineare nei pesi λ; per la continuità servono i risultati generali del capitolo 5 (Teorema 5.2), oppure il rimando a Mayne et al. del paper. Una conseguenza concettuale: come l'MPC del libro, anche il LMPC di un'iterazione avrebbe in linea di principio una forma esplicita, una legge affine a tratti dello stato (capitoli 11–12 di [BBM]). Calcolarla non avrebbe senso, perché cambia a ogni iterazione e la sua complessità cresce con i dati: per il LMPC la soluzione online del QP (capitolo 14 di [BBM]) è la scelta naturale.

10.5 Orizzonte infinito, CLQR e ottimalità

Iterazione sulla funzione valore. La sezione 7.4.1 del libro descrive la *value function iteration*: si parte da una stima della funzione valore su una regione, la si migliora applicando l'equazione di Bellman (5) in ogni punto di una griglia dello spazio di stato, e si interpola tra i punti della griglia. Il LMPC si può leggere come una variante di questa idea guidata dai dati, con tre differenze: i campioni non sono una griglia (il cui numero di punti cresce in modo esponenziale con la dimensione dello stato) ma gli stati che il sistema visita davvero; la stima della funzione valore non si ottiene risolvendo l'equazione di Bellman punto per punto ma *misurando* i costi lungo le traiettorie; e l'interpolazione è convessa, il che garantisce che la stima resti per eccesso (proposizione 5.2(b)) e decresca con le iterazioni (proposizione 5.2(d)). È un'analogia, non un'equivalenza: il paper non presenta il LMPC in questi termini.

Il costo terminale come costo della coda. Commentando la scelta $\mathcal{X}_f = \mathcal{O}_\infty^{\mathrm{LQR}}$, $p(x) = x^\top P_\infty x$, il libro osserva che i due termini del costo dell'MPC "riflettono il costo a orizzonte infinito": la somma sugli N passi è il costo del tratto iniziale, in cui i vincoli possono essere attivi, e il costo terminale è il costo esatto della *coda* infinita, percorsa dentro un insieme in cui i vincoli non sono più attivi (equazioni (12.24)–(12.26) di [BBM]). Nel LMPC P^{j-1} ha la stessa funzione, con due differenze: è definito su una regione molto più grande, in cui i vincoli possono essere attivi, ed è il costo di code *realmente percorse* invece che di una coda calcolata analiticamente.

Orizzonte finito che restituisce l'ottimo infinito. Il Teorema 11.3 del libro (Sznaier e Damborg, Scokaert e Rawlings) afferma che il problema a orizzonte finito con costo terminale $x^\top P_\infty x$ e senza vincolo terminale coincide con il CLQR a orizzonte infinito, se lo stato finale predetto entra "spontaneamente" nell'insieme in cui quel costo terminale è esatto. Il Teorema 3 del paper ha lo stesso spirito: un orizzonte finito restituisce l'ottimo a orizzonte infinito quando il costo terminale descrive correttamente il costo della coda. La differenza è che nel libro la correttezza del costo terminale è garantita da un calcolo, mentre nel LMPC è il punto d'arrivo delle iterazioni.

Il riferimento dell'esempio. La soluzione esatta del CLQR con cui il paper confronta il LMPC (sezione 9) è calcolata con l'algoritmo che il paper attribuisce a Borrelli (2003) e che nel libro è descritto nella sezione 11.3.5: si parte dall'insieme $\mathcal{O}_\infty^{\mathrm{LQR}}$ e si esplorano le regioni vicine risolvendo problemi a orizzonte crescente, fino a coprire l'insieme di stati iniziali di interesse. Il Teorema 11.4 ne descrive il risultato: una legge di controllo continua e affine a tratti su una partizione poliedrica.

10.6 Il doppio integratore nel libro

Il sistema dell'esempio del paper, il doppio integratore $x_{k+1} = \left[\begin{smallmatrix} 1 & 1 \\ 0 & 1 \end{smallmatrix}\right] x_k + \left[\begin{smallmatrix} 0 \\ 1 \end{smallmatrix}\right] u_k$, è il sistema di riferimento del libro (equazione (11.23) di [BBM]), con limiti numerici diversi da quelli del paper. Tre esempi del libro aiutano a leggere il paper:

- [BBM, Esempio 11.1] mostra come si propagano all'indietro gli insiemi ammissibili $\mathcal{X}_i$, con insieme terminale controllo-invariante oppure senza: è l'illustrazione dei Teoremi 11.1–11.2, quindi della regione $K_N(\mathcal{CS}^{j-1})$ della sezione 10.2;
- [BBM, Esempio 11.2] calcola la legge ottima esplicita, affine a tratti, di un CLQR a orizzonte finito: è il tipo di soluzione che il paper usa come termine di confronto;
- [BBM, Esempio 12.1] applica il receding horizon con orizzonte breve e *senza insieme terminale*: da uno stato iniziale il sistema converge, da uno stato vicino il problema di ottimo

diventa impossibile dopo pochi passi, perché le predizioni ad anello aperto non coincidono con l'evoluzione in anello chiuso. È esattamente il fallimento che un insieme terminale controllo-invariante impedisce, e quindi ciò che il safe set convesso garantisce al LMPC.

10.7 Dal MIP al QP: un rilassamento che non perde nulla

Nel LMPC non lineare del 2016 il vincolo terminale $x_{t+N|t} \in \mathcal{SS}^{j-1}$ è un vincolo *logico*: lo stato finale deve coincidere con il primo punto memorizzato, *oppure* con il secondo, *oppure* con il terzo, e così via. Il capitolo 16 del libro (sezione 16.4) mostra come vincoli logici di questo tipo si traducano in disuguaglianze con variabili binarie, e il capitolo 17 (sezione 17.4) come l'MPC che ne risulta richieda di risolvere un MIQP. La sezione 17.4.1 ricorda che questi problemi sono NP-completi e descrive il *branch and bound*: il primo passo dell'algoritmo è *rilassare* le variabili binarie, lasciandole variare con continuità in $[0, 1]$, e risolvere il problema continuo che ne risulta; poi si ramifica fissando le variabili una alla volta.

Il LMPC convesso del paper è esattamente quel primo rilassamento: le binarie $\delta_s^i \in \{0, 1\}$ diventano i pesi $\lambda_s^i \in [0, 1]$. In generale il rilassamento di un MIP fornisce solo un limite inferiore e una soluzione che può non rispettare i vincoli originali; per questo il branch and bound deve proseguire. Il punto del paper è che, *per sistemi lineari*, la soluzione del problema rilassato è già "sicura": lo stato finale è in $\mathcal{CS}^{j-1}$, che è controllo-invariante, e tutte le garanzie restano valide. Non serve ramificare: basta un solo QP. Il problema rilassato non è equivalente al MIP (il suo ottimo è in generale migliore, perché ha più libertà), ma ha le stesse proprietà, ed è questo che spiega il risparmio di tempo osservato nell'esempio.

10.8 Che cosa aggiunge il paper rispetto al libro

- *Ingredienti terminali dai dati.* Nel libro insieme e costo terminali si progettano (LQR e massimo insieme invariante) con operazioni sui poliedri; nel paper si leggono dalle traiettorie registrate, senza alcuna operazione sugli insiemi.

- *La dimensione iterativa.* Il libro tratta un singolo problema di controllo; non contiene l'idea di eseguire il compito più volte e di garantire che il costo non peggiori da un'esecuzione all'altra (Teoremi 2 e 3 del paper).

- *Un uso nuovo dell'interpolazione baricentrica.* Nel libro serve ad approssimare una legge già nota; nel paper serve a costruire un costo terminale da dati non ottimi, sfruttando che la prova del Lemma 13.2 richiede solo ammissibilità e convessità.

- *Dove guardare per estendere il paper.* Gli strumenti per rimuovere le ipotesi più forti sono nel libro: insiemi invarianti robusti e MPC robusto (sezioni 10.3–10.4 e capitolo 15) per disturbi e incertezze di modello; sistemi ibridi e MIQP (capitoli 16–17) per uscire dalla linearità, con il costo computazionale che il paper ha voluto evitare.

11 Ipotesi, limiti e osservazioni

- *Modello esatto e assenza di disturbi.* Tutta la prova di fattibilità ricorsiva usa la (26): lo stato realizzato coincide con quello predetto. Con incertezze di modello o disturbi, i punti memorizzati non sono più traiettorie esatte del modello di predizione e le garanzie cadono; servono versioni robuste, costruite con gli insiemi invarianti robusti e l'MPC robusto del libro [BBM, Sez. 10.3–10.4 e Cap. 15].

- *Linearità.* È l'ipotesi che rende lecita la convessificazione (lemma 2.5). Per sistemi non lineari si torna al safe set discreto, oppure si usano approssimazioni locali (lavori successivi degli stessi autori), rinunciando a parte delle garanzie.

- *Stesso stato iniziale.* Le iterazioni partono tutte da x_S. È ciò che rende la traiettoria precedente una candidata ammissibile all'istante iniziale (passo 1 del teorema 7.1 e prima disuguaglianza del teorema 8.1).
- *Serve una prima traiettoria ammissibile* (ipotesi 6.3). Il LMPC migliora, ma non crea dal nulla la prima soluzione.
- *Crescita dei dati.* Il numero di variabili λ cresce con il numero di stati memorizzati: il QP diventa sempre più grande. Il paper non discute come limitarlo.
- *Iterazioni finite.* La teoria è scritta per traiettorie infinite; la versione pratica tronca le traiettorie quando lo stato ha raggiunto x_F con tolleranza ε, il che introduce piccole approssimazioni non analizzate.
- *Convergenza delle traiettorie.* Il teorema di ottimalità la assume, non la dimostra.

12 Riepilogo

Tabella 4: MPC classico e LMPC a confronto.

	MPC classico	LMPC
Insieme terminale	progettato (es. invariante LQR), spesso piccolo	$\mathcal{CS}^{j-1}$, inviluppo convesso degli stati visitati; cresce con le iterazioni
Costo terminale	progettato (es. $x^\top P_\infty x$)	P^{j-1}, interpolazione convessa dei costi realizzati; diminuisce con le iterazioni
Perché soddisfano la (7)	per costruzione analitica	lemma 5.3: linearità + convessità + costi realmente pagati
Problema a ogni istante	QP	QP con in più i pesi λ
Garanzie	fattibilità ricorsiva, stabilità	le stesse, più miglioramento tra iterazioni e ottimalità della traiettoria limite

I passaggi logici del paper, in sintesi:

1. Un compito iterativo fornisce, a ogni esecuzione, una traiettoria ammissibile e il costo realmente pagato da ogni suo stato.
2. Gli stati visitati sono sicuri (proposizione 4.1). Per un sistema lineare con vincoli convessi lo è anche ogni loro combinazione convessa: il safe set convesso $\mathcal{CS}^j$ è controllo-invariante (proposizione 4.2).
3. Interpolando convessamente i costi realizzati si ottiene P^j, una funzione convessa che sovrastima il costo ottimo e che decresce almeno del costo di stadio lungo opportune combinazioni degli ingressi memorizzati (lemma 5.3).
4. Usando $(\mathcal{CS}^{j-1}, P^{j-1})$ come ingredienti terminali, l'MPC è un problema convesso (QP) e le dimostrazioni classiche danno fattibilità ricorsiva e stabilità (teorema 7.1).
5. Il costo di ogni iterazione è limitato dal costo dell'iterazione precedente (teorema 8.1) e, se le traiettorie convergono, il limite è l'ottimo a orizzonte infinito (teorema 8.2).

6. Rispetto al LMPC non lineare, il passaggio dall'insieme discreto all'inviluppo convesso trasforma un MIP in un QP, con un risparmio computazionale di diversi ordini di grandezza.

7. Nel quadro del libro di Borrelli, Bemporad e Morari (sezione 10): il Teorema 1 è il Teorema 12.2 di [BBM] con $(\mathcal{X}_f, p) = (\mathcal{CS}^{j-1}, P^{j-1})$; P^j è l'interpolazione baricentrica del capitolo 13, applicata a traiettorie realizzate invece che a soluzioni ottime, ed è la funzione valore di un mp-LP (capitolo 6); il passaggio dal MIP al QP è il rilassamento continuo con cui inizia il branch and bound (capitolo 17), che per sistemi lineari conserva tutte le garanzie.

Riferimenti bibliografici

[1] U. Rosolia, F. Borrelli, *Learning Model Predictive Control for Iterative Tasks: A Computationally Efficient Approach for Linear System*, IFAC PapersOnLine 50-1 (2017), 3142–3147.

[2] U. Rosolia, F. Borrelli, *Learning Model Predictive Control for Iterative Tasks*, arXiv:1609.01387 (2016); versione estesa: *Learning Model Predictive Control for Iterative Tasks. A Data-Driven Control Framework*, IEEE Transactions on Automatic Control 63(7) (2018).

[3] D.Q. Mayne, J.B. Rawlings, C.V. Rao, P.O.M. Scokaert, *Constrained model predictive control: Stability and optimality*, Automatica 36(6) (2000), 789–814.

[4] F. Borrelli, *Constrained Optimal Control of Linear and Hybrid Systems*, Springer (2003).

[5] F. Borrelli, A. Bemporad, M. Morari, *Predictive Control for Linear and Hybrid Systems*, Cambridge University Press (2017).

[6] C.N. Jones, M. Morari, *Polytopic approximation of explicit model predictive controllers*, IEEE Transactions on Automatic Control 55(11) (2010), 2542–2553.

[7] D.A. Bristow, M. Tharayil, A.G. Alleyne, *A survey of iterative learning control*, IEEE Control Systems 26(3) (2006), 96–114.

[8] S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press (2004).